

République Algérienne Démocratique et Populaire
Ministère de l'Enseignement Supérieur et de la Recherche
Scientifique



Université de Constantine 03
Salah Bounider
Faculté de Médecine
Département de Médecine



Polycopié du Cours et Travaux Pratiques

Introduction à l'Analyse des Données Biomédicales

-Biostatistique-informatique-

Destiné aux Étudiants de 1ère Année de
Médecine

Rédigé par : Dr. Abdenmour Boulesnane

Année Universitaire : 2022-2023

Avant-propos

Cher(e)s Étudiant(e)s,

Il me fait plaisir de vous présenter ce polycopié dédié au module de Biostatistique-informatique pour les étudiants de première année de médecine. Dans ce module, vous trouverez une introduction complète à l'analyse de données biomédicales et son traitement statistique à l'aide d'Excel et SPSS. Le contenu de ce module est hautement pertinent pour les défis scientifiques actuels en médecine et en médecine computationnelle. L'utilisation efficace des données médicales et l'application de méthodes statistiques et computationnelles sont essentielles pour avancer dans le diagnostic et le traitement des maladies. C'est pourquoi, ce polycopié est conçu pour vous fournir une base solide en statistique et informatique, qui est essentielle pour la recherche en médecine, afin de prendre des décisions éclairées et de mener des recherches de qualité.

Le but de ce polycopié est de vous offrir un support pédagogique clair et complet pour faciliter votre apprentissage. Chaque chapitre commence par un résumé des points clés à retenir, suivi d'une explication détaillée des concepts abordés et de nombreux exemples pour vous aider à bien comprendre les notions présentées. Les travaux pratiques proposés vous permettront de mettre en pratique ces notions et d'acquérir les compétences nécessaires pour réussir dans notre discipline.

Dans les sept chapitres suivants, vous apprendrez à collecter vos données, à les prétraiter en utilisant différentes techniques, à effectuer des analyses statistiques avancées telles que l'analyse de relations entre variables, et à utiliser les distributions de probabilité avec SPSS. Chaque chapitre est accompagné d'exemples pratiques pour vous aider à mieux comprendre les concepts et les techniques abordés.

Nous espérons que ce polycopié vous offrira une expérience d'apprentissage enrichissante et stimulante. Nous vous souhaitons à tous une excellente lecture et une réussite éclatante dans vos études !

Cordialement,

Dr. Abdenmour Boulesnane
Dernière mise à jour le : 2 janvier 2025



Table des matières

Table des figures	v
Liste des tableaux	vii
1 Analyse des Données Biomédicales	1
1.1 Introduction	1
1.2 Science des Données	1
1.2.1 Définition	1
1.2.2 Méthodologie de la Science des Données	2
1.3 Médecine Computationnelle	3
1.3.1 Définition	3
1.3.2 Domaines d'application	4
1.4 Science des données en médecine computationnelle	5
1.4.1 Données Biomédicales	5
1.4.2 Outils d'analyse de données biomédicales	6
1.4.3 Excel	7
1.4.4 Statistical Package for the Social Sciences : SPSS	7
1.5 Conclusion	8
2 Collection de Données avec Excel	9
2.1 Introduction	9
2.2 Démarrer EXCEL	9
2.3 Terminologie	10
2.4 Fenêtre EXCEL	11
2.5 Fichier XLS ou XLSX?	12
2.6 Gestion des Classeurs	12
2.6.1 Créer classeur	12
2.6.2 Ouvrir un classeur	12
2.6.3 Enregistrer un classeur	12
2.7 Cellule Active Et Plage De Cellules	13
2.8 Saisie des Données	13
2.9 Séries de Données	14
2.10 Validation des Variables Statistiques	15
2.10.1 Variables Quantitatives	15
2.10.2 Variables Qualitatives	16
2.11 Conclusion	17
3 Organisation des Données Collectées dans SPSS	18

TABLE DES MATIÈRES

3.1	Introduction	18
3.2	L'Environnement SPSS	18
3.3	Manipulation de Données dans SPSS	20
3.3.1	Définition des métadonnées	21
3.4	Saisie et affichage des éléments de données dans l'onglet «Vue de données»	24
3.5	Sauvegarde des données SPSS	25
3.6	Ouverture de fichiers de données SPSS	25
3.7	Transfert de données d'un fichier Excel vers SPSS	25
3.8	Conclusion	27
4	Prétraitement des Données	28
4.1	Introduction	28
4.2	Navigation dans le SPSS Visualiseur (Viewer)	28
4.3	Jouer avec les données dans SPSS	29
4.4	Remplacement des valeurs manquantes	29
4.5	Trier les observations	31
4.6	Recoder les variables	31
4.7	Supprimer une Variable ou une Observation	33
4.8	Fractionnement des Données	34
4.9	Sélection des Données	35
4.9.1	Condition Logique Simple	35
4.9.2	Condition Logique Complexe	38
4.10	Conclusion	40
5	Analyse des Données	41
5.1	Introduction	41
5.2	Collection de Données dans SPSS	41
5.3	Prétraitement des Données dans SPSS	42
5.4	Utilisation des Statistiques Descriptives	43
5.4.1	Fréquences pour les variables catégorielles (qualitatives)	43
5.4.2	Fréquences pour les variables continues	46
5.4.3	Résumer des variables continues avec la procédure descriptive	48
5.5	Conclusion	48
6	Analyse des Relations entre les Variables Statistiques	49
6.1	Introduction	49
6.2	Collection de Données dans SPSS	49
6.3	Prétraitement des données dans SPSS	50
6.4	Distributions Statistiques à Deux Caractères	50
6.4.1	Relations entre variables catégorielles (qualitatives)	50
6.4.2	Relations entre variables quantitatives	52
6.5	Représentation graphique des données	56
6.5.1	Construire des graphiques à la manière du Générateur de graphiques	57
6.5.2	Affichage d'une relation linéaire	59
6.6	Conclusion	60
7	Distributions de Probabilité avec SPSS	61

7.1	Introduction	61
7.2	Distribution Binomiales (distribution discrète finie)	62
7.3	Distribution Normale (distribution continue)	64
7.3.1	Probabilités Normales	64
7.3.2	Centiles Normaux	66
7.3.3	Estimation par Intervalles de confiance	67
7.4	Conclusion	69
	Travaux Pratiques	70
	Références bibliographiques	84

Table des figures

1.1	Organigramme de la méthodologie de la science des données . . .	2
1.2	Recherches en médecine computationnelle	4
2.1	Environnement Excel	10
2.2	Utilisation de l'apostrophe	14
2.3	Glissement de cellule Excel	14
2.4	Validation des données quantitatives	15
2.5	Validation des données qualitatives	16
2.6	Résultat de la validation des données qualitatives	16
3.1	Environnement SPSS	19
3.2	Données SPSS	20
3.3	Vue des variables	21
3.4	Type de variable	22
3.5	Libellés de valeurs	23
3.6	Valeurs manquantes	24
3.7	Enregistrer les données dans SPSS	25
3.8	Ouvrir les données dans SPSS	26
3.9	Ouvrir la source de données Excel	26
4.1	IBM SPSS statistics viewer	28
4.2	Fichier de données SPSS	29
4.3	Menu Méthode	30
4.4	Remplacement les valeurs manquantes	30
4.5	Résultat après le remplacement	30
4.6	Trier les observations	31
4.7	Boîte de dialogue : Création de variables	32
4.8	Boîte de dialogue : Anciennes et nouvelles valeurs	33
4.9	Résultat après le Recodage	33
4.10	Fichier scindé	34
4.11	Résultat des fréquences	35
4.12	Sélectionner des observations	36
4.13	Expression conditionnelle	36
4.14	Résultat après la sélection	37
4.15	Résultat des fréquences	37
4.16	Expression conditionnelle	39
4.17	Résultat après la sélection	40
5.1	Fichier de données SPSS	41

5.2	Résultat après le tri	42
5.3	Résultat après le fractionnement	42
5.4	Boîte de dialogue Fréquences	43
5.5	Boîte de dialogue Fréquences :Statistiques	44
5.6	Boîte de dialogue Fréquences :Graphiques	44
5.7	Résultat de l'analyse	45
5.8	Boîte de dialogue Fréquences	46
5.9	Boîte de dialogue Fréquences :Graphiques	47
5.10	Résultat de l'analyse	47
5.11	Résultat de statistiques descriptives	48
6.1	Fichier de données SPSS	50
6.2	Résultat après le tri	50
6.3	Boîte de dialogue Tableaux croisés	51
6.4	Résultat des tableaux croisés	52
6.5	Corrélations Bivariées	53
6.6	Tableau des corrélations	54
6.7	Boîte de dialogue Régression linéaire	55
6.8	Résultat de la régression linéaire	56
6.9	Générateur de graphiques	57
6.10	Boîte à Moustaches :1D pour la variable Bloodsugar	58
6.11	Nuage de points de deux variables quantitatives	59
6.12	Droite de régression linéaire	60
7.1	Boîte de dialogue : Calculer la variable	63
7.2	Résultat après le calcul des probabilités binomiales	63
7.3	Représentation graphique des probabilités	64
7.4	Boîte de dialogue : Calculer la variable	65
7.5	La zone sous la courbe à gauche de x ($p(X < x) = 0,9$) [uiowa, 2024].	66
7.6	Boîte de dialogue : Calculer la variable	67
7.7	Résultat après l'application de la fonction IDF.NORMAL	67
7.8	Vue des variables	68
7.9	Boîte de dialogue : Calculer la variable	69
7.10	Résultat de l'estimation	69

Liste des tableaux

2.1	XLS vs XLSX	12
2.2	Variables quantitatives et qualitatives	15
4.1	Conjonction et disjonction logique	38
6.1	Analyses des relations statistiques	51

Chapitre 1

Analyse des Données Biomédicales

1.1 Introduction

L'analyse des données biomédicales est importante, car elle permet aux chercheurs d'identifier les modèles de maladies, de développer des modèles prédictifs, de faciliter le développement de médicaments, de permettre une médecine personnalisée et d'intégrer des données provenant de plusieurs sources pour fournir une image plus complète de la santé des patients. Grâce à ces applications, l'analyse des données biomédicales joue un rôle crucial dans l'avancement de notre compréhension des maladies et dans le développement de nouveaux traitements et thérapies pour améliorer les résultats pour les patients.

1.2 Science des Données

1.2.1 Définition

La science des données est un domaine interdisciplinaire qui implique l'extraction, le traitement, l'analyse, la visualisation et l'interprétation d'ensembles de données volumineux et complexes. Il utilise une combinaison de méthodes statistiques et informatiques pour découvrir des modèles et des informations à partir de données qui peuvent éclairer la prise de décision et fournir un avantage concurrentiel.

La science des données implique une gamme de compétences, y compris l'analyse statistique, l'apprentissage automatique, la visualisation des données et la gestion des données. Cela implique souvent de travailler avec des ensembles de données volumineux et divers provenant de diverses sources, notamment les médias sociaux, les transactions de commerce électronique, les capteurs, les dossiers médicaux et les données financières.

L'objectif de la science des données est de transformer les données en informations exploitables qui peuvent éclairer la prise de décision, améliorer l'efficacité et fournir un avantage concurrentiel. Les scientifiques des données utilisent

une gamme d'outils et de techniques pour atteindre cet objectif, notamment le nettoyage et le prétraitement des données, l'analyse exploratoire des données, l'ingénierie des fonctionnalités, la sélection et la validation des modèles et la visualisation des données.

La science des données a un large éventail d'applications dans tous les secteurs, notamment la santé, la finance, le marketing, les médias sociaux et le commerce électronique. Parmi les exemples d'applications de science des données, citons la détection des fraudes, les systèmes de recommandation, le marketing personnalisé, la maintenance prédictive et le diagnostic médical.

1.2.2 Méthodologie de la Science des Données

La méthodologie de la science des données est une approche systématique de résolution de problèmes basés sur les données qui implique plusieurs étapes clés (voir Figure 1.1) :




FIGURE 1.1 – Organigramme de la méthodologie de la science des données

1. **Collection de données** : Cela implique d'identifier les sources de données pertinentes, de collecter les données et de les stocker dans un format structuré.
2. **Préparation des données** : Cela implique le nettoyage, la transformation et le prétraitement des données pour les rendre aptes à l'analyse.
3. **L'analyse et L'analyse exploratoire des données** : L'analyse exploratoire des données (EDA) et l'analyse des données sont deux méthodes liées, mais distinctes d'analyse des données.

L'EDA est une étape préliminaire dans l'analyse des données qui implique l'utilisation de diverses techniques statistiques et de visualisation pour explorer et comprendre les données. L'objectif de l'EDA est de découvrir des modèles, des tendances et des anomalies dans les données qui peuvent éclairer le processus d'analyse des données. L'EDA implique des techniques telles que les histogrammes, les boîtes à moustaches, les diagrammes de dispersion et les matrices de corrélation pour explorer

visuellement les données et identifier les principales caractéristiques et relations.

L'analyse des données, en revanche, est un processus plus formel et structuré d'analyse des données qui implique l'application de techniques statistiques et d'apprentissage automatique aux données. Le but de l'analyse des données est d'obtenir des informations et de faire des prédictions à partir des données en utilisant une méthodologie bien définie. L'analyse des données implique des techniques telles que les tests d'hypothèses, l'analyse de régression, la classification et le regroupement pour modéliser et analyser les données.

Bien que l'EDA et l'analyse des données soient des processus distincts, ils sont souvent utilisés ensemble dans le flux de travail d'analyse des données.

4. **Ingénierie des caractéristiques** : Cela implique de sélectionner et de transformer les caractéristiques ou variables pertinentes dans les données pour créer de nouvelles caractéristiques qui amélioreront les performances des modèles.
5. **Sélection et validation des modèles** : cela implique de sélectionner les modèles d'apprentissage automatique ou statistiques appropriés, de les entraîner sur les données et d'évaluer leurs performances à l'aide de métriques et de techniques de validation appropriées.
6. **Déploiement** : il s'agit de déployer le modèle dans un environnement de production et de l'intégrer dans le flux de travail de l'entreprise.

La méthodologie de la science des données est un processus itératif qui consiste à faire des allers-retours entre ces étapes jusqu'à ce qu'une solution satisfaisante soit trouvée. Cela nécessite une combinaison de compétences techniques, de connaissances du domaine et de créativité pour développer des solutions efficaces à des problèmes complexes axés sur les données.

1.3 Médecine Computationnelle

1.3.1 Définition

La médecine computationnelle est un domaine interdisciplinaire qui combine des principes de l'informatique, des mathématiques et de l'ingénierie avec la médecine pour développer des outils et des modèles informatiques pour résoudre des problèmes de santé. Cela implique l'utilisation d'approches basées sur les données, la modélisation informatique et la simulation pour améliorer le diagnostic médical, le traitement et les soins aux patients.

La médecine computationnelle vise à fournir des soins médicaux personnalisés et précis grâce à l'utilisation de modèles et de simulations basés sur les données. Ces modèles peuvent aider à identifier les facteurs de risque, à prédire la progression de la maladie et à optimiser les plans de traitement. Par exemple, les algorithmes d'apprentissage automatique peuvent être utilisés pour analyser des images médicales afin de détecter les premiers signes de cancer ou d'identifier des modèles dans de grands ensembles de données qui peuvent être utilisés pour développer des plans de traitement plus efficaces.




FIGURE 1.2 – Recherches en médecine computationnelle

Certaines des applications de la médecine computationnelle comprennent la découverte et le développement de médicaments, l'imagerie médicale et le diagnostic, la modélisation prédictive, la classification des maladies et la médecine personnalisée. La médecine computationnelle est un domaine en croissance rapide qui a le potentiel de transformer les soins de santé en fournissant des méthodes de diagnostic et de traitement plus précises et plus efficaces.

1.3.2 Domaines d'application

La médecine computationnelle a un large éventail d'applications dans divers domaines, notamment :

1. **Imagerie médicale** : La médecine computationnelle peut être utilisée pour analyser des images médicales telles que des IRM, des tomodensitogrammes et des rayons X pour faciliter le diagnostic, la planification du traitement et la surveillance des maladies.
2. **Génomique et médecine personnalisée** : La médecine computationnelle peut être utilisée pour analyser les données génomiques afin d'identifier les mutations pathogènes, de prédire le risque de maladie et d'élaborer des plans de traitement personnalisés.
3. **Dossiers de santé électroniques** : La médecine computationnelle peut être utilisée pour analyser les dossiers de santé électroniques (DSE) afin d'identifier les modèles de maladie, de prédire les résultats de la maladie et d'élaborer des plans de traitement personnalisés.
4. **Découverte et développement de médicaments** : La médecine computationnelle peut être utilisée pour identifier de nouvelles cibles médicamenteuses, concevoir et optimiser des molécules médicamenteuses et prédire la toxicité des médicaments.
5. **Essais cliniques** : La médecine computationnelle peut être utilisée pour concevoir et analyser des essais cliniques afin d'améliorer leur efficacité et leur efficacité.
6. **Santé publique** : la médecine computationnelle peut être utilisée pour analyser les données de santé publique afin d'identifier les épidémies, de

prévoir la propagation des maladies et d'élaborer des stratégies de prévention et de contrôle des maladies.

7. **Dispositifs médicaux et capteurs** : la médecine computationnelle peut être utilisée pour développer et optimiser des dispositifs médicaux et des capteurs pour le diagnostic, la surveillance et le traitement des maladies.
8. **Informatique de santé** : La médecine computationnelle peut être utilisée pour développer et analyser des systèmes informatiques de santé afin d'améliorer la prestation des soins de santé et les résultats pour les patients.

En résumé, la médecine computationnelle a diverses applications dans divers domaines, notamment l'imagerie médicale, la génomique et la médecine personnalisée, les dossiers de santé électroniques, la découverte et le développement de médicaments, les essais cliniques, la santé publique, les dispositifs et capteurs médicaux et l'informatique de la santé.

1.4 Science des données en médecine computationnelle

La science des données joue un rôle essentiel dans la médecine computationnelle. L'abondance de données médicales générées à partir de diverses sources, y compris les dossiers de santé électroniques, l'imagerie médicale, la génomique et les appareils portables, a créé un besoin d'approches axées sur les données pour analyser et interpréter ces données.

Les méthodes de la science des données, telles que l'apprentissage automatique, la modélisation statistique et l'exploration de données, peuvent être utilisées pour extraire des modèles et des informations à partir de données médicales qui peuvent éclairer le diagnostic médical, le traitement et les soins aux patients. Par exemple, les algorithmes d'apprentissage automatique peuvent être utilisés pour analyser des images médicales afin de détecter les premiers signes de cancer ou d'identifier des modèles dans de grands ensembles de données qui peuvent être utilisés pour développer des plans de traitement plus efficaces.

En médecine computationnelle, la science des données peut être utilisée pour développer des modèles prédictifs capables de prévoir la progression de la maladie ou de prédire les résultats pour les patients. La science des données peut également être utilisée pour identifier les facteurs de risque et personnaliser les plans de traitement en fonction de données spécifiques au patient, telles que les informations génétiques, les antécédents médicaux et les facteurs liés au mode de vie.

Dans l'ensemble, la science des données est un élément crucial de la médecine computationnelle, car elle permet aux chercheurs et aux cliniciens d'exploiter les vastes quantités de données médicales disponibles pour améliorer le diagnostic médical, le traitement et les soins aux patients.

1.4.1 Données Biomédicales

Les données biomédicales désignent tout type de données liées à la santé humaine et à la biologie. Il peut inclure un large éventail d'informations, telles que

les dossiers médicaux des patients, les données d'essais cliniques, les données génomiques, les données d'imagerie et de nombreux autres types de données liées à la santé.

Les données biomédicales sont généralement utilisées pour mieux comprendre les mécanismes de la maladie, identifier les traitements potentiels et améliorer les soins aux patients. Avec l'essor de l'analyse des mégadonnées et de l'intelligence artificielle, l'utilisation des données biomédicales suscite un intérêt croissant pour développer des modèles prédictifs et des approches de médecine personnalisée.

Cependant, les données biomédicales soulèvent également d'importantes préoccupations en matière d'éthique et de confidentialité, en particulier compte tenu de la nature sensible des données et du potentiel d'utilisation abusive. À ce titre, des réglementations strictes régissent la collecte, le stockage et l'utilisation des données biomédicales afin de garantir qu'elles sont traitées de manière responsable et éthique.

1.4.2 Outils d'analyse de données biomédicales

Il existe de nombreux outils disponibles pour analyser les données biomédicales, notamment :

1. **Progiciels statistiques** : les logiciels statistiques tels que R, SAS, Python et **SPSS** sont couramment utilisés pour analyser les données biomédicales, y compris les essais cliniques et les études épidémiologiques.
2. **Outils de visualisation de données** : des outils tels que Tableau, MATLAB et **Excel** peuvent être utilisés pour créer des visualisations de données biomédicales, telles que des graphiques et des diagrammes, afin d'identifier des modèles et des tendances.
3. **Outils d'apprentissage automatique et d'intelligence artificielle** : ces outils, tels que TensorFlow et Keras, peuvent être utilisés pour développer des modèles prédictifs et identifier des modèles dans de grands ensembles de données biomédicales.
4. **Outils d'analyse génomique** : Des outils tels que GATK, SAMtools et Picard peuvent être utilisés pour analyser les données génomiques, y compris les données de séquençage de l'ADN et les données d'expression génique.
5. **Outils d'analyse d'imagerie** : des logiciels tels que ImageJ et OsiriX peuvent être utilisés pour analyser les données d'imagerie médicale, y compris les tomodensitogrammes, les IRM et les radiographies.
6. **Outils d'analyse de réseau** : Ces outils, tels que Cytoscape et Gephi, peuvent être utilisés pour analyser des réseaux biologiques complexes et identifier les relations entre les différents composants.
7. **Outils d'exploration de texte et de traitement du langage naturel** : ces outils, tels que Pubmed et MetaMap, peuvent être utilisés pour extraire des informations de la littérature biomédicale et des dossiers de santé électroniques.

Ce ne sont là que quelques exemples des nombreux outils disponibles pour analyser les données biomédicales. Le choix de l'outil dépendra des besoins spécifiques du chercheur et de la nature des données analysées.

1.4.3 Excel

Excel est un progiciel de tableur couramment utilisé pour l'analyse et la gestion de données dans de nombreux domaines, y compris la recherche biomédicale. Bien qu'Excel puisse être utile pour certains types d'analyse de données biomédicales, ce n'est peut-être pas le progiciel le plus approprié pour tous les types de données biomédicales.

Une limitation d'Excel est qu'il a une limite maximale sur le nombre de lignes et de colonnes pouvant être traitées, ce qui peut être un problème pour les grands ensembles de données. De plus, Excel ne dispose pas de fonctionnalités intégrées pour l'analyse statistique avancée ou la visualisation des données, ce qui peut limiter son utilité pour certains types d'analyse de données biomédicales.

Cependant, Excel peut être utile pour les tâches de gestion de données de base telles que la saisie de données, le tri, le filtrage et les calculs de base. Il peut également être utile pour générer des tableaux et des graphiques simples pour visualiser les données. De plus, Excel peut être utilisé pour suivre des données expérimentales ou créer des feuilles de calcul de base pour calculer des mesures statistiques de base telles que la moyenne, la médiane et l'écart type.

1.4.4 Statistical Package for the Social Sciences : SPSS

SPSS signifie Statistical Package for the Social Sciences, qui est un progiciel utilisé pour l'analyse statistique dans les sciences sociales, y compris la psychologie, la sociologie et d'autres domaines connexes. C'est un outil populaire pour analyser les données dans les études de recherche et il est largement utilisé dans les milieux universitaires et commerciaux.

SPSS offre une interface conviviale pour effectuer des analyses statistiques, permettant aux chercheurs de saisir facilement des données, d'exécuter des analyses et de générer des tableaux et des graphiques pour présenter les résultats. Certains des tests statistiques pouvant être effectués à l'aide de SPSS comprennent les tests t, l'ANOVA, l'analyse de régression, l'analyse factorielle et l'analyse par grappes.

SPSS fournit également une large gamme d'outils de gestion et de transformation des données, tels que le tri, la fusion et le recodage des données, qui peuvent être utiles pour préparer les données à analyser.

En outre, SPSS peut être utile pour certains types d'analyse de données biomédicales, telles que l'analyse de données d'enquête ou l'exécution de tests statistiques sur des données d'essais cliniques. Il fournit une interface conviviale pour la saisie et l'analyse des données, et peut générer des tableaux et des graphiques pour présenter les résultats.

Dans l'ensemble, SPSS est un outil puissant et polyvalent pour l'analyse statistique, en particulier pour ceux qui travaillent dans les sciences des données. Il est conçu pour être facile à utiliser, même pour ceux qui ont des connaissances statistiques limitées, et peut produire des résultats précis et fiables.

1.5 Conclusion

Dans l'analyse de données biomédicales, Excel est souvent utilisé pour des analyses simples et la visualisation de données de base, tandis que SPSS est utilisé pour des analyses statistiques plus complexes, telles que l'analyse de régression, l'ANOVA et l'analyse factorielle. Ces deux outils sont importants pour les chercheurs biomédicaux, car ils offrent un moyen flexible et convivial d'analyser et de présenter des données.

Chapitre 2

Collection de Données avec Excel

2.1 Introduction


La collecte de données est un élément essentiel de la recherche biomédicale, car elle contribue à générer les informations et les connaissances nécessaires pour faire progresser notre compréhension des maladies et développer de nouveaux traitements et thérapies. Sans collecte de données, il serait difficile de faire progresser la recherche biomédicale et d'améliorer les résultats pour les patients.

Dans la recherche biomédicale, Excel est couramment utilisé pour la collecte de données. Excel est un outil polyvalent qui permet aux utilisateurs de créer des feuilles de calcul personnalisées pour stocker et organiser les données de manière structurée. Il offre également des fonctionnalités telles que la validation des données, des formules et des modèles qui peuvent aider à garantir l'exactitude des données, à rationaliser l'analyse des données et à standardiser la collecte des données.

2.2 Démarrer EXCEL


Il existe différentes méthodes de démarrage d'Excel :

- Menu démarrer : Bouton démarrer → tous les programmes → Microsoft Office → Microsoft Office Excel 2007
- Raccourci : Pour faciliter le lancement d'Excel, il est préférable de créer un raccourci sur le Bureau. Ensuite, double-cliquer sur ce raccourci pour démarrer Excel.




2.3 Terminologie

Excel, Classeur, Feuille de calcul, colonne, ligne, cellule, référence cellule (voir Figure 2.1).



(a)



(b)

FIGURE 2.1 – Environnement Excel

- Un fichier Excel est nommé Classeur. Il peut contenir plusieurs feuilles de calcul (7). Par défaut, il contient trois feuilles de calcul : Feuil1, Feuil2 et Feuil3. Chaque feuille de calcul est constituée de colonnes (8) et des lignes (9). L'intersection de ces colonnes et lignes donne des cellules.
- Chaque colonne est référencée par une, deux ou trois lettres (A, B, C, ..., MC, MD, ...XFC, XFD) (16384 colonnes). Les lignes sont numérotées (1, 2, ..., 1048576). La référence d'une cellule est obtenue par la combinaison de la référence de sa colonne et le numéro de sa ligne (sans espace entre les deux). L'intersection entre la 4e colonne (D) et la 6e ligne donne la cellule D6.
- Par défaut, les cellules sont vides, mais elles peuvent contenir de valeurs.

2.4 Fenêtre EXCEL

■ Bouton office **(1)** : Ce bouton est situé dans le coin supérieur à gauche de la fenêtre Excel. Il ouvre le menu office qui contient deux volets. Le volet droit affiche la liste des classeurs récemment utilisés. Le volet gauche affiche la liste de commandes souvent utilisées : "Nouveau", "Ouvrir", "Enregistrer", "Imprimer", etc. (voir Figure 2.1).

■ Barre de titre **(2)** : Elle indique le nom du classeur en cours, suivi du nom de l'application utilisée (Microsoft Excel). À droite, il existe les trois boutons **(10)** : réduire, niveau inférieur (agrandir) et fermer.

■ Barre d'outils accès rapide **(3)** : Elle contient les boutons de commandes fréquemment utilisés (vous pouvez les utiliser sans passer par les onglets). Par défaut, elle affiche les trois boutons (enregistrer, annuler et de répéter). Mais on peut la personnaliser en y ajoutant d'autres outils tels que nouveau, ouvrir ou impression rapide, etc.

■ Ruban : il s'affiche sous la barre de titre. Le ruban est organisé hiérarchiquement ; il comporte plusieurs onglets **(4)** et **(44)**. Ils peuvent être des onglets fixes **(4)** : "Accueil, Insertion, Mise en page, Formules, Données, Révision et Affichage" ou des onglets contextuels **(44)**. Ces derniers s'affichent lorsque vous sélectionnez un objet spécifique. Les onglets contextuels affichés dépendent de l'objet qui est sélectionné. Par exemple : la sélection d'un graphique fait apparaître les trois onglets contextuels Outils de graphique **(44)** : création, disposition, mise en forme. Ensuite, chaque onglet est divisé en plusieurs groupes qui comportent des boutons de commande et des galeries. Par exemple : l'onglet Accueil comporte les groupes : "Presse-papiers, Police, Alignement, Nombre, Style, Cellules et Édition". Remarque : vous pouvez réduire le ruban (masquer les groupes) : double-cliquez sur l'onglet actif (**[Ctrl] + [F1]**) :

- Pour réafficher les groupes temporairement, faire un simple clic sur un onglet.
- Pour restaurer le ruban, double-cliquez de nouveau sur un onglet.

■ Zone de nom **(5)** : elle affiche l'adresse ou le nom de la cellule active (actuellement sélectionnée) ou de la sélection. Une cellule est active à la fois. Elle est entourée d'une bordure épaisse.

■ Barre de formule **(6)** : elle affiche le contenu de la cellule active. Elle peut être utilisée pour la saisie ou la modification du contenu de cette cellule.

■ Poignée de la recopie **(12)** : le petit carré noir dans le coin inférieur droit d'une cellule (lorsque vous pointez sur la poignée de recopie, le pointeur se transforme en croix noire).

2.5 Fichier XLS ou XLSX ?

Voir la Table 2.1.



Excel 97-2003	Excel 2007
Dans un classeur xls, les limites sont de 65 536 lignes et 256 colonnes, ce qui correspond à la colonne IV.	Maintenant, avec un classeurxlsx, les limites sont de 1 048 576 lignes et 16 384 colonnes, qui est la colonne XFD.
	

TABLE 2.1 – XLS vs XLSX

2.6 Gestion des Classeurs

2.6.1 Créer classeur

Pour créer un nouveau classeur **[Ctrl]+[N]** : Bouton Office ⇒ Nouveau ⇒ Nouveau Classeur Excel ⇒ Créer.

2.6.2 Ouvrir un classeur

Pour ouvrir un classeur depuis Excel **[Ctrl]+[O]** : Bouton Office ⇒ Ouvrir

2.6.3 Enregistrer un classeur

Excel offre plusieurs choix pour enregistrer un nouveau classeur (le créer physiquement) et le conserver sur votre disque dur :

1. Bouton Office ⇒ Enregistrer (**[ctrl]+[S]**)
2. Cliquer sur la disquette  de la barre d'outils accès rapide (**[ctrl]+[S]**)
3. Bouton Office ⇒ Enregistrer sous (**[F12]**).

Lorsque vous utilisez une de ces méthodes d'enregistrement (1, 2 ou 3) pour la première fois, la boîte de dialogue "enregistrer sous" s'affiche, dans laquelle vous spécifiez :

- ✓ Le nom du fichier
- ✓ Le disque et le dossier de sauvegarde
- ✓ Le type de fichier : le format de fichier souhaité pour l'enregistrement. Par défaut, les classeurs sont enregistrés au format (.xlsx) (Excel 2007)

2.7 Cellule Active Et Plage De Cellules

■ La cellule active est celle dans laquelle la saisie sera enregistrée. Elle se distingue par une bordure plus marquée. Par défaut, A1 est la cellule active à l'ouverture du classeur. L'adresse (ou le nom) et le contenu de la cellule active sont affichés dans la zone de nom et la barre de formule respectivement.

■ Tout rectangle de cellules est appelé "plage de cellules", ou "plage". Pour désigner une plage de cellules, il est courant d'utiliser la référence de la première cellule en haut à gauche suivie d'un double-point et de la référence de la dernière cellule en bas à droite.

Exemple :

- A1 :B3 fait référence aux cellules : A1, B1, A2, B2, A3, B3
- C1 :E3 fait référence aux cellules : C1, D1, E1, C2, D2, E2, C3, D3, E3
- A1 :A8 fait référence aux cellules : A1, A2, A3, A4, A5, A6, A7, A8
- A1 :E1 fait référence aux cellules : A1, B1, C1, D1, E1

2.8 Saisie des Données

Avant saisir de données dans une cellule, il faut la sélectionner.

❖ Texte

- Le texte est automatiquement aligné à gauche.
- Le texte ne passe pas à la ligne même s'il est long et dépasse la largeur de la colonne.
- Pour passer à la ligne suivante : **[alt]+[entrée]** au sein d'une cellule
- Si le texte commence par " + ", " - " ou " = ", Excel affiche un message d'erreur "(#NOM?)" car il interprète ce texte comme une formule. Pour éviter cela, ajoutez une apostrophe « ' » avant le texte (exemple : '+Médecine).
- Ajouter une apostrophe « ' » avant un nombre pour que ce dernier soit interprété comme un texte (exemple : '2019 dans la cellule A2).

❖ Nombre

- Le nombre est automatiquement aligné à droite.
- Pour saisir un nombre négatif, il faut le précéder du signe " - " ou le mettre entre parenthèses.
- L'écriture 32e9 signifie $32 * 10^9$ c.-à-d. 32 suivis de neuf zéros.

❖ Date

- La date est automatiquement alignée à droite.
- Pour entrer une date dans une cellule, vous pouvez la saisir sous la forme : jj/mm/aaaa ou jj-mm-aaaa.
- Pour saisir la date d'aujourd'hui, tapez **[ctrl]+[;]** (cette date est constante).
- Pour qu'une date soit interprétée comme un texte, faites-la précéder par une apostrophe « ' » (exemple : '2019) (voir Figure 2.2).




FIGURE 2.2 – Utilisation de l'apostrophe

2.9 Séries de Données

- Taper Patient, Date, dans les cellules A1, B1 respectivement.
- Sélectionner la cellule A1, faire glisser la poignée de recopie sur quelques cellules (vers le bas) (voir Figure 2.3).
- Pour les dates vous avez la possibilité d'incrémenter par jour mois...




FIGURE 2.3 – Glissement de cellule Excel

2.10 Validation des Variables Statistiques

Les variables sont utilisées pour décrire les individus d'une population. Chaque colonne correspond à une variable.

■ Une variable a un nom : "ID", "Age", "poids" ...

■ Une variable a une valeur à un certain moment : MED01 , 22 ans, 59 kg (chaque ligne représente un individu, unité statistique ...)

TABLE 2.2 – Variables quantitatives et qualitatives

Types de variables			
Quantitative (Numérique)		Qualitative (Catégorielle)	
Continue	Discrète	Ordinale	Nominale
Se compose de valeurs numériques qui peuvent être mesurées, mais pas comptées (infinie).	Se compose de valeurs numériques qui peuvent être mesurées et comptées (finie).	Se compose de texte ou d'étiquettes qui ont un ordre logique.	Se compose de texte ou d'étiquettes sans ordre logique.
Par exemple. Poids {56,06 kg, 87 kg}	Par exemple. Nombre d'enfants {0, 1, 2, 3,..., 10}	Par exemple. Taille de la tumeur {petite, moyenne, grande}	Par exemple. Sexe {Homme, Femme}

2.10.1 Variables Quantitatives

■ En utilisant la fenêtre "Validation des données", il est possible de limiter une saisie en imposant des restrictions telles que la saisie d'un nombre entier.

Exemple : pour la variable age : Pour restreindre la saisie à des nombres entiers supérieurs à 0, commencez par sélectionner les cellules concernées. (avant la saisie de ces valeurs) dans notre exemple C2 :C6 (l'étape S1). Ensuite **Données** → **Outils de données** → **Validation des données** (S2 et S3). Choisir Autoriser : **nombre entier** (S4). Ensuite Données : **supérieur à** et taper 0 dans source (S5) (voir Figure 2.4).




FIGURE 2.4 – Validation des données quantitatives

Notes :

■ Pour les variables quantitatives continues, nous choisissons **Décimal** dans

2.10. Validation des Variables Statistiques

la liste "Autoriser".

■ Dans la liste "Données", vous avez plusieurs choix comme : **supérieur à**, **inférieure à**, **comprise entre**..., etc.

2.10.2 Variables Qualitatives

■ Sélectionner les cellules où vous allez saisir le sexe (l'étape E1 dans la figure suivante) (dans notre exemple B2 :B6) (voir Figure 2.5).




FIGURE 2.5 – Validation des données qualitatives

Ensuite, choisir autoriser "liste" (E4) dans : **Données**→**validation des données**→**validation de données** (E2 et E3). Taper les éléments de la liste (**homme** ; **femme**) dans le champ source (E5) (séparés par point-virgule ;).

Le résultat sera :

	A	B	C	D
1	ID	sexe	age	poids
2	MED01		19	55,5
3	MED02	homme	18	67
4	MED03	femme	22	59
5	MED04		18	54
6	MED05		21	60,5
7				

FIGURE 2.6 – Résultat de la validation des données qualitatives

Note :

■ Veuillez trouver le fichier de données Excel de ce chapitre à partir de ce lien : <https://aboutesnane.net/wp-content/datafiles/DATAEXCEL2.xlsx>

2.11 Conclusion

Excel est un outil populaire pour la collecte de données dans la recherche biomédicale. Pour collecter des données efficacement avec Excel, il est important de planifier votre feuille de calcul, d'utiliser la validation des données pour garantir l'exactitude, d'utiliser des formules pour rationaliser l'analyse et de sécuriser vos données. Par conséquent, Excel peut être un outil puissant pour organiser et analyser les données dans la recherche biomédicale.