

Chapitre 3

Organisation des Données Collectées dans SPSS

3.1 Introduction

SPSS (Statistical Package for the Social Sciences) est un outil logiciel puissant largement utilisé pour organiser, analyser et visualiser des données dans la recherche sociale et biomédicale. Il offre une gamme d'options personnalisables pour l'organisation et la gestion des données, de puissants outils statistiques pour l'analyse des données et une documentation claire et transparente pour la reproductibilité.

3.2 L'Environnement SPSS

L'environnement SPSS se compose de plusieurs composants, comme le montre l'image ci-dessous (Figure 3.1) :

1. La barre de titre : affiche le nom du fichier actuel et de l'application.
2. La barre de menus : Cette barre donne accès à différentes commandes qui sont regroupées selon leur fonction. SPSS a un certain nombre d'options de menu situées en haut de l'écran (comme tout autre programme informatique). Ouvrez SPSS et sélectionnez chacune des options de menu une par une.
 - ◆ **Le menu 'Fichier' (raccourci Alt + F)** : Essentiellement, ce menu vous permet d'ouvrir des fichiers existants, d'en créer de nouveaux et d'imprimer ou d'enregistrer tout ce sur quoi vous travaillez. Les listes Données récemment utilisées et Fichiers récemment utilisés sont utiles, car elles vous permettent d'accéder rapidement aux fichiers que vous avez récemment ouverts ou sur lesquels vous avez travaillé.
 - ◆ **Le menu 'Edition' (raccourci Alt + E)** : Ce menu devrait vous être familier si vous avez déjà utilisé des traitements de texte. Annuler et Rétablir peuvent aider à rectifier les erreurs que vous faites. Couper, Copier et Coller vous permettent de déplacer des blocs de nombres

Organisation des Données Collectées dans SPSS




FIGURE 3.1 – Environnement SPSS

d'une zone de la feuille de calcul à une autre. Chercher... et Aller à l'observation... vous permet de localiser un score de données ou un participant particulier, ce qui est très pratique lorsque vous traitez un grand nombre de données.

- ◆ **Le menu 'Affichage' (raccourci Alt + V) :** Le menu Affichage traite des aspects visuels de la feuille de calcul, en particulier : quelles barres d'outils sont affichées, quelles polices sont utilisées, pour voir les lignes de la grille sur la feuille de calcul ou les étiquettes de valeur sont affichées pour vos variables..., etc.
- ◆ **Le menu 'Données' (raccourci Alt + D) :** Ce menu vous permet d'organiser votre fichier de données. Il est peu probable que vous utilisiez initialement la plupart des options de ce menu ; cependant, quelques-unes des options peuvent être utiles. Par exemple, vous pouvez identifier certaines erreurs potentielles commises lors de la saisie de données en signalant d'éventuelles entrées de données en double à l'aide de l'outil **Identifier les observations dupliquées**.
- ◆ **Le menu 'Transformer' (raccourci Alt + T) :** Ce menu vous permet de manipuler vos variables.
- ◆ **Le menu 'Analyser' (raccourci Alt + A) :** C'est le menu que vous utiliserez probablement le plus et dont vous aurez initialement besoin : Statistiques descriptives, Comparer les moyennes, Modèle linéaire général, Corrélation et Régression,..., etc.
- ◆ **Le menu 'Marketing direct' (raccourci Alt + M) :** C'est plus pour les entreprises qui souhaitent réaliser des études de marché. Vous n'aurez pas besoin d'utiliser ce menu !
- ◆ **Le menu 'Graphiques' (raccourci Alt + G) :** Ce menu vous permet de présenter les données sous forme graphique, ce qui vous aidera à mieux comprendre vos données. Il existe plusieurs façons de créer

des graphiques dans SPSS, mais c'est un bon point de départ.

- ◆ **Le menu 'Utilitaires' (raccourci Alt + U)** : En pratique, il est utile pour créer des analyses personnalisées et automatisées. ..., mais n'hésitez pas à l'ignorer pour l'instant !
 - ◆ **Le menu 'Fenêtre' (raccourci Alt + W)** : Ce menu vous permet d'accéder rapidement à d'autres fenêtres qui pourraient être masquées.
 - ◆ **Le menu 'Aide' (raccourci Alt + H)** : Ce menu peut être très utile, car il vous offre de l'aide et des informations à la fois sur le système du programme lui-même et sur les tests statistiques qu'il propose.
3. La barre d'outils : fournit des raccourcis vers des commandes de menu couramment utilisés.
 4. La fenêtre de l'éditeur de données : Le nom en tête de chaque colonne est le nom de la variable, c'est-à-dire le nom que vous utiliserez pour faire référence à une variable, tandis que, chaque ligne représente une observation (un cas).
 5. Les onglets : vue de données et vue des variables : vue de données est l'endroit où nous inspectons nos données réelles et la vue des variables est l'endroit où nous voyons des informations supplémentaires sur nos données.
 6. La barre de statut : en bas de chaque fenêtre, SPSS fournit plusieurs informations telles que : l'état de la commande, l'état du filtre, etc.

3.3 Manipulation de Données dans SPSS

■ Les données SPSS ont trois composants principaux : les observations, les variables et les métadonnées. Lorsque vous recevez des données, vous aurez rarement un problème avec les observations, occasionnellement un problème avec les variables, mais presque toujours un problème avec les métadonnées.




FIGURE 3.2 – Données SPSS




FIGURE 3.3 – Vue des variables

■ SPSS peut lire des données à partir de divers formats, notamment des bases de données, des fichiers texte, Microsoft Excel, CSV... etc. Vous pouvez également taper directement dans SPSS; et, vous pouvez même coller les données copiées dans SPSS.

3.3.1 Définition des métadonnées

■ Dans SPSS, les données sont organisées sous forme d'observations (lignes) et chaque observation est constituée d'un ensemble de variables (colonnes). Tout d'abord, vous définissez les caractéristiques des variables qui composent une observation, puis vous entrez les données dans les variables qui composent le contenu des observations.

■ Pour saisir des données dans SPSS, utilisez l'onglet «Vue des variables ». Comme vous pouvez le voir dans la figure ci-dessous (voir Figure 3.3), les attributs de la variable (tels que le nom, le type et la largeur) sont définis en haut de la fenêtre. Tout ce que vous avez à faire est d'entrer quelque chose dans chaque colonne pour chaque variable.

■ Les 11 caractéristiques sont les seuls nécessaires pour spécifier complètement tous les attributs d'une variable. Lorsque vous ajoutez une nouvelle variable, vous constaterez que des valeurs par défaut raisonnables apparaissent pour la plupart des caractéristiques. Les 11 caractéristiques d'une variable sont :

1. **Nom** : Cliquez simplement sur la cellule et saisissez un court descriptif, tel que : Age, revenu, sexe, patient... Bien que vous puissiez saisir des noms plus longs ici, il est recommandé de les maintenir courts, car ils seront utilisés dans des listes nommées ainsi que pour des balises d'identification sur des graphiques de données et autres formats où l'espace peut




FIGURE 3.4 – Type de variable

être limité.

- Les noms de variables doivent commencer par une lettre (A-Z ou a-z).
 - Ils peuvent contenir des lettres, des chiffres (0-9) et des caractères de soulignement (_).
 - Aucun autre caractère spécial, espace ou accent n'est permis.
 - Le nom ne doit pas être un mot-clé réservé par SPSS, comme ALL, BY, AND, etc.
 - Chaque nom de variable dans le même fichier de données doit être unique.
 - Les noms de variables ne peuvent pas débuter par un chiffre.
2. **Type** : La plupart des données que vous saisirez ne seront que des nombres normaux. Cependant, les données telles que la devise doivent être affichées dans un format spécial, et les données telles que les dates nécessitent des procédures de calcul spéciales. Pour ce type de données, il vous suffit de spécifier le type dont vous disposez et SPSS s'occupe des détails pour vous. Pour afficher la boîte de dialogue illustrée à la Figure 3.4, sélectionnez une cellule dans la colonne Type, puis cliquez sur le bouton représenté par trois points qui apparaît.
 3. **Largeur** : La colonne largeur dans la définition d'une variable détermine le nombre de caractères utilisés pour afficher la valeur. Si la valeur à afficher n'est pas assez grande pour remplir l'espace, la sortie sera complétée par des blancs. S'il est plus grand que vous ne l'avez spécifié, il sera reformaté pour s'adapter ou des astérisques seront affichés.
 4. **Décimales** : La colonne Décimales contient le nombre de chiffres qui apparaissent à droite de la virgule décimale lorsque la valeur apparaît à l'écran.
 5. **Libellé** : Le nom et le libellé ont le même objectif fondamental : ce sont des descripteurs qui identifient la variable. La différence est que le nom est l'identifiant court et l'étiquette est le long. Vous pouvez également ignorer la définition du libellé. Si vous n'avez pas d'étiquette définie pour une variable, SPSS utilisera le nom de variable que vous avez défini pour tout.

6. **Valeurs** : La colonne Valeurs est l'emplacement où vous pouvez assigner des libellés à toutes les valeurs possibles d'une variable. Pour afficher la boîte de dialogue illustrée à la Figure 3.5, sélectionnez une cellule dans la colonne Valeurs, puis cliquez sur le bouton représenté par trois points qui apparaît.




FIGURE 3.5 – Libellés de valeurs

Normalement, vous faites une seule entrée pour chaque valeur possible qu'une variable peut prendre. Mais, par exemple, pour une variable nommée Sexe, vous pouvez affecter la valeur 1 à l'étiquette Homme et 2 à l'étiquette Femme. Si vous définissez des libellés, votre sortie peut afficher des étiquettes au lieu de valeurs.

Pour définir un libellé pour une valeur, procédez comme suit :

- (a) Dans la zone Valeur, entrez la valeur.
 - (b) Dans la zone Libellé, entrez un libellé.
 - (c) Cliquez sur le bouton Ajouter. (La valeur et l'étiquette apparaissent dans le grand bloc de texte.)
 - (d) Pour modifier ou supprimer une définition, sélectionnez-la simplement dans le bloc de texte, apportez vos modifications, puis cliquez sur le bouton Changer.
 - (e) Répétez les étapes 1 à 4 si nécessaire.
 - (f) Pour enregistrer les étiquettes de valeur et fermer la boîte de dialogue, cliquez sur OK.
7. **Manquant** : Vous pouvez spécifier des codes pour les données manquantes. Pour afficher la boîte de dialogue illustrée à la Figure 3.6, sélectionnez une cellule dans la colonne Manquant. Un bouton représenté par trois points apparaîtra, cliquez dessus pour ouvrir la boîte de dialogue.

3.4. Saisie et affichage des éléments de données dans l'onglet «Vue de données»




FIGURE 3.6 – Valeurs manquantes

Par exemple, supposons que vous saisissiez des réponses à des questions, et que l'une des questions soit : " Combien d'enfants avez-vous?" La réponse normale à cette question est un nombre, vous définissez donc le type de variable comme un nombre. Vous pouvez définir -99 comme la valeur saisie lorsque la réponse est « Je ne me souviens pas » et -98 peut être utilisé lorsque la réponse est « Je ne peux pas dire ».

8. **Colonnes** : Dans l'attribut Colonnes, vous pouvez spécifier la largeur de la colonne à utiliser pour saisir les données.
9. **Align** : La colonne Align détermine la position des données dans son espace alloué.
10. **Mesure** : Votre valeur pour l'attribut Mesure spécifie le niveau de mesure de votre variable. Voici le niveau des options de mesure dans SPSS :
 - **Nominal** : Une valeur qui spécifie une catégorie ou un type de chose. Vous pouvez avoir 0 pour Désapprouver et 1 pour Approuver. Ou vous pouvez utiliser 1 pour signifier Femme et 2 pour signifier Homme.
 - **Ordinal** : Une valeur qui spécifie la position (ordre) de quelque chose dans une liste. Par exemple, premier, deuxième et troisième sont des nombres ordinaux.
 - **Échelle** : Un nombre qui spécifie une magnitude. L'échelle peut être la distance, le poids, l'âge ou un décompte de quelque chose.
11. **Rôle** : Vous n'avez pas besoin de vous soucier de la colonne Rôle pour le moment.

3.4 Saisie et affichage des éléments de données dans l'onglet «Vue de données»

Après avoir défini les variables, vous pouvez commencer à saisir les données. Cliquez sur l'onglet **Vue de données** de la fenêtre de l'éditeur de données. En haut des colonnes, vous voyez les noms des variables. La saisie de données dans l'une de ces cellules est simple : il vous suffit de cliquer sur la cellule et de commencer à taper.

3.5 Sauvegarde des données SPSS

Tout ce que vous avez à faire est de choisir **Fichier → Enregistrer ou Enregistrer sous, (Ctrl + S)** sélectionnez votre type de fichier, puis entrez un nom de fichier. The SPSS Statistics File Format is **«.sav»** (voir Figure 3.7).




FIGURE 3.7 – Enregistrer les données dans SPSS

Vous avez le choix entre de nombreux types de fichiers : formats de texte brut, formats de feuille de calcul Excel, formats Lotus, formats dBase, formats SAS, format SYLK, format Portable et 18 formats Stata.

3.6 Ouverture de fichiers de données SPSS

Pour ouvrir un fichier de données, choisissez **Fichier → Ouvrir → Données ou (Ctrl + O)** et sélectionnez le fichier à charger. Lorsque vous le faites, les noms de variables et les données sont chargés dans SPSS.

3.7 Transfert de données d'un fichier Excel vers SPSS

Pour ouvrir votre fichier Excel dans SPSS :

1. **Fichier → Ouvrir → Données (Ctrl + O)**, dans le menu SPSS.
2. Sélectionnez le type de fichier que vous souhaitez ouvrir, Excel *.xls *.xlsx, *.xlsm .

3.7. Transfert de données d'un fichier Excel vers SPSS




FIGURE 3.8 – Ouvrir les données dans SPSS

3. Dans la boîte de dialogue "Ouvrir les données", sélectionnez le fichier que vous souhaitez ouvrir (voir Figure 3.8)..
4. Cliquez sur **Ouvrir**.
5. La boîte de dialogue suivante apparaît (Figure 3.9).




FIGURE 3.9 – Ouvrir la source de données Excel

6. Cliquez sur **OK**.

Note :

■ Veuillez trouver le fichier de données SPSS de ce chapitre à partir de ce lien : <https://aboutlesnane.net/wp-content/datafiles/DataSPSS3.sav>

3.8 Conclusion

L'organisation des données collectées dans SPSS est importante pour une gestion précise et efficace des données, la reproductibilité des résultats de recherche, la sécurité et la confidentialité des données de recherche et la collaboration entre les chercheurs. SPSS offre une interface conviviale et des options personnalisables pour organiser les données, telles que le recodage, les transformations de données et le nettoyage des données. SPSS permet une gestion des données rapide et efficace, comme la possibilité d'importer et d'exporter des données à partir de différentes sources, de fusionner des ensembles de données et de nettoyer des données. Dans l'ensemble, l'organisation des données collectées dans SPSS est essentielle pour mener des recherches fiables et valides en sciences sociales et biomédicales.

Chapitre 4

Prétraitement des Données

4.1 Introduction

Le prétraitement des données est une étape cruciale de l'analyse des données qui implique le nettoyage, la transformation et la préparation des données brutes pour l'analyse. Il contribue à améliorer la qualité, la précision et la compatibilité des données avec les techniques d'analyse et les outils logiciels. Le prétraitement des données peut également réduire le temps et les efforts requis pour l'analyse des données en rationalisant le processus de nettoyage et de transformation des données, et peut aider à créer des visualisations et des résumés des données qui facilitent la compréhension et l'interprétation des données.

4.2 Navigation dans le SPSS Visualiseur (Viewer)

Lorsque vous exécutez une analyse, produisez un graphique ou même l'enregistrement d'un fichier, **la fenêtre SPSS Statistics Viewer** apparaît automatiquement pour afficher ce que vous avez créé (Figure 4.1).




FIGURE 4.1 – IBM SPSS statistics viewer

Prétraitement des Données

■ Le volet de plan (1), sur la gauche, contient un aperçu de toutes les informations stockées dans le Viewer.

■ Le volet de contenu (2), à droite, contient les tableaux statistiques, les graphiques et les textes.

■ Pour masquer un objet dans le volet de contenu, il faut :

✓ Sélectionnez l'objet (table, graphe..) depuis le volet de plan ou le volet de contenu.

✓ Cliquez sur l'icône du livre dans la barre d'outils .

✓ Pour afficher à nouveau cet objet, appuyez sur l'icône .

Masquer des éléments sans les supprimer permet à l'utilisateur de se concentrer plus facilement sur les résultats qui l'intéressent tout en conservant tous les résultats.

4.3 Jouer avec les données dans SPSS

	Patient	Weight	Bloodsugar	Sexe	Bloodgroup
1	P1	53,00	1,20	1	1
2	P2	-99,00	1,50	1	3
3	P3	88,00	1,40	2	2
4	P4	45,00	,60	1	4
5	P5	90,00	2,40	2	2
6	P6	175,00	3,60	2	1

FIGURE 4.2 – Fichier de données SPSS

1. Télécharger le fichier de données SPSS appelé « DataSPSS4.sav » sur : <https://aboulesnane.net/wp-content/datafiles/DataSPSS4.sav>
2. Les données contiennent cinq variables nommées : Patient, Weight, Bloodsugar, Sexe, et Bloodgroup (voir la Figure 4.2).
 - (a) La Variable « **Patient** » est une variable de type Chaîne.
 - (b) La Variable « **Weight** » est une variable quantitative continue de type Numérique. (Pour la variable Weight, on représente les valeurs manquantes par le nombre -99 (voir Figure 3.6)).
 - (c) La Variable « **Bloodsugar** » est une variable quantitative continue de type Numérique.
 - (d) Les valeurs possibles pour la variable qualitative « **Sexe** » : 1=Homme et 2=Femme.
 - (e) Les valeurs possibles pour la variable qualitative « **Bloodgroup** » : 1=AB , 2=A, 3=B et 4=O.

4.4 Remplacement des valeurs manquantes

Afin de remplacer les valeurs manquantes par des valeurs acceptables, nous utiliserons des paramètres de position centrale tels que la moyenne, la médiane, le mode...etc. Par exemple, dans la variable **Weight** de nos données,

4.4. Remplacement des valeurs manquantes

nous avons une valeur manquante représentée par -99. Afin de ne pas perturber la distribution de nos données, nous pouvons remplacer cette valeur par une valeur moyenne de la série. Pour cela :

1. Choisissez **Transformer → Remplacer les valeurs manquantes** : la boîte de dialogue **Remplacer les valeurs...** apparaît.
2. Passez la variable **Weight** vers la zone «**Nouvelles variables**».
3. Dans le menu **Méthode**, (voir Figure 4.3), vous pouvez sélectionner la meilleure méthode utilisée pour remplacer les valeurs manquantes (Interpolation linéaire, Paramètres de position centrale...). Dans notre cas, nous utiliserons **Moyenne série**.




FIGURE 4.3 – Menu Méthode

4. Cliquez sur **OK** (voir la Figure 4.4).




FIGURE 4.4 – Remplacement les valeurs manquantes

En conséquence, une nouvelle colonne apparaît avec le nom « **Weight_1** » où la valeur -99 est remplacée par la valeur moyenne 90,2 (voir la Figure 4.5).

	Patient	Weight	Bloodsugar	Sexe	Bloodgroup	Weight_1
1	P1	53,0	1,2	1	1	53,0
2	P2	-99,0	1,5	1	3	90,2
3	P3	88,0	1,4	2	2	88,0
4	P4	45,0	,6	1	4	45,0
5	P5	90,0	2,4	2	2	90,0
6	P6	175,0	3,6	2	1	175,0

FIGURE 4.5 – Résultat après le remplacement

4.5 Trier les observations

1. Choisissez **Données → Trier les observations** : la boîte de dialogue **Trier les observations** s'affiche (Figure 4.6).




FIGURE 4.6 – Trier les observations

2. Sélectionnez la variable **Weight**.
3. Cliquez sur **OK** pour trier les données.

■ L'ordre dans lequel les données sont affichées n'affecte jamais l'analyse. Vous trie les données uniquement pour mieux voir les informations dans l'éditeur de données.

■ Il est possible de trier les données soit par ordre croissant, soit par ordre décroissant. Notez que par défaut, les données sont triées par ordre **croissant**.

■ Le tri peut être basé sur un ou plusieurs critères.

Note :

■ Pour annuler le tri :

✓ Nous ne pouvons pas annuler le tri des données.

✓ Une astuce consiste à trier à nouveau les données en fonction de la variable « **Patient** » (répétez la même procédure vue ci-dessus juste nous sélectionnons la variable **Patient** plutôt que **Weight**).

4.6 Recoder les variables

En réencodant les variables, nous pouvons regrouper un ensemble de valeurs dans certaines catégories prédéfinies en fonction du type de données. Ce processus permet d'économiser des efforts et du temps pour reconstruire les données collectées d'une meilleure manière.

Par exemple, supposons que nous voulions ré-encoder la variable **Weight**, où nous regrouperons chaque ensemble de valeurs comme suit :

1. Featherweight : [0-50]
2. Middleweight :]50-90]
3. Heavyweight :]90-120]
4. Super Heavyweight : >120

Voici comment le faire dans SPSS :

1. Choisissez **Transformer → Création de variables** : la boîte de dialogue **Création de variables** apparaît.
2. Cliquez sur le bouton fléché pour déplacer la variable **Weight** vers la zone de travail à droite.
3. Nommez la nouvelle variable de sortie dans la case à droite comme **Weight-Cat** → Cliquez sur le bouton **Changer** pour enregistrer le nouveau nom de variable, comme le montre la Figure 4.7.




FIGURE 4.7 – Boîte de dialogue : Création de variables

4. Cliquez sur le bouton **Anciennes et nouvelles valeurs**.
5. Pour les catégories 1, 2 et 3 : on sélectionne le bouton radio **Plage** → Entrer les valeurs Min et Max → A côté du bouton radio **Valeur** : on entre le numéro de la catégorie → Cliquer sur le bouton **Ajouter** (Voir Figure 4.8).
6. Pour la catégorie 4 : on sélectionne le bouton radio **Plage, de la valeur au MAXIMUM** → Entrer la valeur Min (c.a.d. 120) → A côté du bouton radio **Valeur** : on entre le numéro de la catégorie (c.a.d. 4) → Cliquer sur le bouton **Ajouter** (Voir Figure 4.8).




FIGURE 4.8 – Boîte de dialogue : Anciennes et nouvelles valeurs

7. Cliquez sur **Poursuivre**, puis sur **OK**. La figure 4.9 ci-dessous montre le résultat final.

	Patient	Weight	Bloodsugar	Sexe	Bloodgroup	WeightCat
1	P1	53,00	1,20	1	1	2,00
2	P2	90,20	1,50	1	3	3,00
3	P3	88,00	1,40	2	2	2,00
4	P4	45,00	,60	1	4	1,00
5	P5	90,00	2,40	2	2	2,00
6	P6	175,00	3,60	2	1	4,00

FIGURE 4.9 – Résultat après le Recodage

Il sera utile de dire à quiconque regarde votre sortie ce que représentent ces valeurs recodées. Pour ce faire, cliquez sur l'onglet **Vue des variables** en bas de la feuille de calcul, puis cliquez dans la zone Values (sur la nouvelle variable **WeightCat**) et ajoutez des étiquettes de valeur comme indiqué précédemment (c.a.d. 1=Featherweight, 2=Middleweight, 3=Heavyweight, 4=Super Heavyweight).

4.7 Supprimer une Variable ou une Observation

► Supposons que nous voulions supprimer la nouvelle variable **WeightCat**. Pour supprimer une variable dans la vue des données, cliquez sur le nom de la variable et appuyez sur la touche **Suppr** du clavier, ou cliquez avec le bouton droit sur le nom de la variable et appuyez sur **Effacer**.

► Pour supprimer une observation (une ligne entière de données), suivez ces étapes : Cliquez sur le numéro d'observation à gauche (la ligne entière sera mise en surbrillance), Appuyez sur **Suppr** sur le clavier, ou cliquez avec le bouton droit sur le numéro d'observation et appuyez sur **Effacer**.




FIGURE 4.10 – Fichier scindé

4.8 Fractionnement des Données

Parfois, dans les études comparatives, nous divisons les données en plusieurs groupes en fonction de certains critères, puis effectuons nos analyses sur chaque sous-groupe séparément. Le fractionnement des données permet de réaliser ce processus.

1. Choisissez **Données → Scinder un fichier** : la boîte de dialogue **Fichier scindé** apparaît.
2. Sélectionnez le bouton radio **Comparer les groupes**.
3. Choisissez **Sexe** comme variable de comparaison et cliquez sur **OK** (voir la Figure 4.10).

Note : Après ce processus, nous remarquons qu'il n'y a pas de changement significatif, sauf que les données ont été à nouveau organisées en fonction du sexe des patients.

4. Choisissez **Analyse → Statistiques descriptives → Fréquences**.
5. Choisissez **Bloodgroup** et placez-la dans la zone Variable(s).
6. Cliquez sur **OK** : la sortie résultante, illustrée dans la Figure 4.11, est groupée par **Sexe**.

➔ Fréquences

Statistiques						
Bloodgroup						
Homme	N	Valide				3
		Manquant				0
Femme	N	Valide				3
		Manquant				0

Bloodgroup						
Sexe			Fréquence	Pourcentage	Pourcentage valide	Pourcentage cumulé
Homme	Valide	AB	1	33,3	33,3	33,3
		B	1	33,3	33,3	66,7
		O	1	33,3	33,3	100,0
		Total	3	100,0	100,0	
Femme	Valide	AB	1	33,3	33,3	33,3
		A	2	66,7	66,7	100,0
		Total	3	100,0	100,0	

FIGURE 4.11 – Résultat des fréquences

Notes :

- Le fractionnement peut être basé sur un ou plusieurs critères.
- Pour annuler le fractionnement, vous devez :
 1. Choisissez **Données → Scinder un fichier**.
 2. Sélectionnez le bouton radio **Analyser toutes les observations, ne pas créer de groupes**, puis cliquez sur le bouton **OK** (ou appuyez sur le bouton **Réinitialiser → OK**).

4.9 Sélection des Données

4.9.1 Condition Logique Simple

1. Choisissez **Données → Sélectionner des observations** : la boîte de dialogue Sélectionner les observations apparaît, comme illustré à la Figure 4.12.
2. Sélectionnez le bouton radio **Selon une condition logique**, puis cliquez sur le bouton **Si...** : Vous pouvez maintenant spécifier les critères de sélection (voir Figure 4.13).
3. Déplacez la variable **Sexe** de la liste de gauche vers la zone d'expression (en haut à gauche) : vous pouvez déplacer la variable soit en la faisant glisser, soit en la sélectionnant puis en cliquant sur le bouton fléché.
4. Utilisez votre clavier ou le clavier numérique à l'écran pour saisir **=2** dans la zone d'expression.




FIGURE 4.12 – Sélectionner des observations




FIGURE 4.13 – Expression conditionnelle

5. Cliquez sur **Poursuivre**, puis sur **OK**. La figure ci-dessous montre le résultat final. Les barres obliques sur certains ID de ligne (dans la première colonne) indiquent que les patients (**hommes**) sont ignorés (pour le moment) et que seules les patientes (**femmes**) sont analysées. La variable *filter_\$* est également créée et comprend 0 et 1 pour les cas non sélectionnés et les cas sélectionnés, respectivement (voir Figure 4.14).

	Patient	Weight	Bloodsugar	Sexe	Bloodgroup	filter_\$
1	P1	53,00	1,20	1	1	0
2	P2	90,20	1,50	1	3	0
3	P3	88,00	1,40	2	2	1
4	P4	45,00	,60	1	4	0
5	P5	90,00	2,40	2	2	1
6	P6	175,00	3,60	2	1	1

FIGURE 4.14 – Résultat après la sélection

Pour voir les effets de la sélection :

- Choisissez **Analyse → Statistiques descriptives → Fréquences**.
- Choisissez **Bloodgroup** et placez-la dans la zone Variable(s).
- Cliquez sur **OK** : la sortie résultante, illustrée dans la figure ci-dessous (Figure 4.15), SPSS affiche uniquement les résultats des groupes sanguins des patientes Femmes.

Fréquences

Statistiques

Bloodgroup

N	Valide	3
	Manquant	0

Bloodgroup

		Fréquence	Pourcentage	Pourcentage valide	Pourcentage cumulé
Valide	AB	1	33,3	33,3	33,3
	A	2	66,7	66,7	100,0
	Total	3	100,0	100,0	

FIGURE 4.15 – Résultat des fréquences

4.9.2 Condition Logique Complexe

Les conditions logiques sont des concepts fondamentaux en logique et en programmation, permettant de prendre des décisions en fonction de l'évaluation de certaines expressions qui aboutissent à vrai (True : T) ou faux (False : F).

Conjonction

Table de vérité de la conjonction (& : **ET**) (T : True, F : False)

P	Q	P ∧ Q
T	T	T
T	F	F
F	T	F
F	F	F

Disjonction

Table de vérité de la disjonction (| : **OU**) (T : True, F : False)

P	Q	P ∨ Q
T	T	T
T	F	T
F	T	T
F	F	F

TABLE 4.1 – Conjonction et disjonction logique

1. Opérateurs logiques

Les opérateurs logiques suivants permettent de combiner ou modifier des affirmations :

- **ET** ($\wedge$, &) :
 - Une expression est vraie si **toutes** les conditions sont vraies.
 - Exemple : $A \wedge B$ est vrai si A **et** B sont vrais.
- **OU** ($\vee$, |) :
 - Une expression est vraie si **au moins une** condition est vraie.
 - Exemple : $A \vee B$ est vrai si A ou B (ou les deux) sont vrais.
- **NON** ($\neg$, ~) :
 - Inverse une condition. Vrai devient faux, et faux devient vrai.
 - Exemple : $\neg A$ est vrai si A est faux.

2. Propriétés des opérateurs logiques

- **Propriété commutative** :

$$A \wedge B = B \wedge A$$

$$A \vee B = B \vee A$$

- **Propriété associative** :

$$(A \wedge B) \wedge C = A \wedge (B \wedge C)$$

$$(A \vee B) \vee C = A \vee (B \vee C)$$

— **Propriété distributive :**

$$A \wedge (B \vee C) = (A \wedge B) \vee (A \wedge C)$$

$$A \vee (B \wedge C) = (A \vee B) \wedge (A \vee C)$$

— **Identité :**

$$A \wedge \mathbf{vrai} = A$$

$$A \vee \mathbf{faux} = A$$

— **Idempotence :**

$$A \wedge A = A$$

$$A \vee A = A$$

— **Absorption :**

$$A \vee (A \wedge B) = A$$

$$A \wedge (A \vee B) = A$$

— **Lois de De Morgan :**

$$\neg(A \wedge B) = (\neg A \vee \neg B)$$

$$\neg(A \vee B) = (\neg A \wedge \neg B)$$

► Essayons maintenant de sélectionner des hommes qui ont un poids supérieur ou égal à 50 ou des patients qui ont un groupe sanguin A.

► Taper la condition suivante : **(Sexe = 1 & Weight >= 50) | Bloodgroup = 2**, (voir Figure 4.16) (Les parenthèses entre les conditions sont très importantes).




FIGURE 4.16 – Expression conditionnelle

Le résultat de la sélection sera :

	Patient	Weight	Bloodsugar	Sexe	Bloodgroup	filter_\$
1	P1	53,00	1,20	Homme	AB	Selected
2	P2	90,20	1,50	Homme	B	Selected
3	P3	88,00	1,40	Femme	A	Selected
4	P4	45,00	,60	Homme	O	Not Selected
5	P5	90,00	2,40	Femme	A	Selected
6	P6	175,00	3,60	Femme	AB	Not Selected

FIGURE 4.17 – Résultat après la sélection

Notes :

■ Pour annuler la sélection, vous devez :

1. Choisissez **Données → Sélectionner des observations**.
2. Sélectionnez le bouton radio **Toutes les observations**, puis cliquez sur le bouton **OK** (ou appuyez sur le bouton **Réinitialiser → OK**).

■ La sélection peut être basée sur un ou plusieurs critères.

4.10 Conclusion

Le prétraitement des données est une étape importante dans l'analyse des données, et SPSS fournit plusieurs outils et techniques pour un prétraitement efficace des données. SPSS peut aider à améliorer la qualité, la précision et la compatibilité des données avec les techniques d'analyse et les outils logiciels, et peut faciliter la création d'informations significatives à partir des données.

Chapitre 5

Analyse des Données

5.1 Introduction

Dans l'analyse des données biomédicales, les variables qualitatives et continues sont souvent analysées ensemble pour mieux comprendre des phénomènes complexes, tels que les facteurs de risque d'une maladie particulière ou l'efficacité d'un traitement médical. Par conséquent, il est important d'avoir une compréhension approfondie des méthodes statistiques pour les deux types de variables afin d'interpréter avec précision les données biomédicales et de prendre des décisions éclairées.

5.2 Collection de Données dans SPSS

	Patient	Weight	Bloodsugar	Sexe	Bloodgroup
1	P1	63,00	1,20	1	1
2	P2	90,20	1,70	1	3
3	P3	88,00	1,40	2	2
4	P4	45,00	,60	1	4
5	P5	90,00	2,40	2	2
6	P6	175,00	3,60	2	1
7	P7	63,00	2,10	1	2

FIGURE 5.1 – Fichier de données SPSS

1. Télécharger le fichier de données SPSS appelé "**DataSPSS5.sav**" sur : <https://aboulesnane.net/wp-content/datafiles/DataSPSS5.sav>
2. Les données contiennent cinq variables nommées : Patient, Weight, Bloodsugar, Sexe, et Bloodgroup (voir la Figure 5.1).
 - (a) La Variable "**Patient**" est une variable de type **Chaîne**.
 - (b) La Variable "**Weight**" est une variable quantitative continue de type Numérique.

5.3. Prétraitement des Données dans SPSS

- (c) La Variable "**Bloodsugar**" est une variable quantitative continue de type Numérique.
- (d) Les valeurs possibles pour la variable qualitative "**Sexe**" : 1=Homme et 2=Femme.
- (e) Les valeurs possibles pour la variable qualitative "**Bloodgroup**" : 1=AB , 2=A, 3=B et 4=O.

5.3 Prétraitement des Données dans SPSS

■ Les données des patients ont été triées en fonction de leurs valeurs de glycémie (**Bloodsugar**) et de poids (**Weight**). (voir section 4.5).

Le résultat du tri est :

	Patient	Weight	Bloodsugar	Sexe	Bloodgroup
1	P4	45,00	,60	1	4
2	P7	60,00	1,20	1	2
3	P1	63,00	1,20	1	1
4	P3	88,00	1,40	2	2
5	P2	90,20	1,70	1	3
6	P5	90,00	2,40	2	2
7	P6	175,00	3,60	2	1

FIGURE 5.2 – Résultat après le tri

■ Les données des patients ont été fractionnées en fonction de leurs valeurs de groupe sanguin (**Bloodgroup**). (voir section 4.8).

Le résultat du fractionnement est :

	Patient	Weight	Bloodsugar	Sexe	Bloodgroup
1	P1	63,00	1,20	1	1
2	P6	175,00	3,60	2	1
3	P7	60,00	1,20	1	2
4	P3	88,00	1,40	2	2
5	P5	90,00	2,40	2	2
6	P2	90,20	1,70	1	3
7	P4	45,00	,60	1	4

FIGURE 5.3 – Résultat après le fractionnement

5.4 Utilisation des Statistiques Descriptives

5.4.1 Fréquences pour les variables catégorielles (qualitatives)

■ La technique la plus courante pour décrire les données catégorielles - niveaux de mesure nominaux et ordinaux - consiste à demander **un tableau de fréquence**, qui fournit un résumé indiquant le nombre et le pourcentage de cas entrant dans chaque catégorie d'une variable. Les utilisateurs peuvent également demander des statistiques récapitulatives supplémentaires telles que le mode ou la médiane, entre autres.

■ Voici comment exécuter la procédure des fréquences afin de pouvoir créer un tableau des fréquences qui vous permettra d'obtenir des statistiques récapitulatives pour les variables qualitatives :

1. Choisissez **Analyse → Statistiques descriptives → Fréquences** : La boîte de dialogue Fréquences apparaît. Dans cet exemple, et basant sur le **fractionnement des données précédent**, vous souhaitez étudier la distribution de variable **Sexe** (Homme, Femme) pour chaque valeur de **Bloodgroup** (AB, A, B, O).
2. Sélectionnez la variables **Sexe**, et placez-la dans la zone Variable(s), comme illustrée à la Figure 5.4.




FIGURE 5.4 – Boîte de dialogue Fréquences

3. Cliquez sur le bouton **Statistiques** : la boîte de dialogue **Fréquences : Statistiques** s'affiche (voir Figure 5.5).
4. Dans la section **Tendance centrale**, cochez la case **Mode**, comme illustrée dans la figure ci-dessous. Cette boîte de dialogue fournit de nombreuses statistiques, mais il est essentiel que vous demandiez uniquement celles qui correspondent au niveau de mesure des variables que vous avez placées dans la zone Variable(s). Pour les variables nominales, la mesure de tendance centrale la plus appropriée est le **mode**, car ces

5.4. Utilisation des Statistiques Descriptives

variables n'ont ni ordre ni hiérarchie. Pour les variables ordinales, on privilégie la **médiane**, qui tient compte de l'ordre des catégories, mais le mode peut également être utilisé si l'on souhaite identifier la catégorie la plus fréquente.

5. Cliquez sur **Poursuivre**.




FIGURE 5.5 – Boîte de dialogue Fréquences :Statistiques

6. Cliquez sur le bouton **Graphiques** : la boîte de dialogue **Fréquences : Graphiques** s'affiche.
7. Dans la section **Type de graphique**, sélectionnez le bouton radio **Graphiques à barres** ; dans la section Valeurs du graphique, sélectionnez le bouton radio **Pourcentages** (voir Figure 5.6).




FIGURE 5.6 – Boîte de dialogue Fréquences :Graphiques

8. Cliquez sur **Poursuivre**, puis sur **OK** : SPSS exécute la procédure des fréquences et calcule les statistiques récapitulatives, le tableau des fréquences et le graphique à barres que vous avez demandés.
9. La sortie résultante, illustrée dans les figures ci-dessous, est groupée par **Bloodgroup** (voir Figure 5.7).

➔ Fréquences

Statistiques			
Sexe			
AB	N	Valide	2
		Manquant	0
	Mode		1 ^a
A	N	Valide	3
		Manquant	0
	Mode		2
B	N	Valide	1
		Manquant	0
	Mode		1
O	N	Valide	1
		Manquant	0
	Mode		1


a. Présence de plusieurs modes. La plus petite valeur est affichée.

(Effectif)
Fréquences
absolues


(Fréquence)
Fréquences
relatives (%)

Fréquences
cumulés (%)


Sexe			Fréquence	Pourcentage	Pourcentage valide	Pourcentage cumulé
Bloodgroup						
AB	Valide	Homme	1	50,0	50,0	50,0
		Femme	1	50,0	50,0	100,0
		Total	2	100,0	100,0	
A	Valide	Homme	1	33,3	33,3	33,3
		Femme	2	66,7	66,7	100,0
		Total	3	100,0	100,0	
B	Valide	Homme	1	100,0	100,0	100,0
O	Valide	Homme	1	100,0	100,0	100,0




(a)



(b)



(c)



(d)

FIGURE 5.7 – Résultat de l'analyse

Note :

Dans IBM SPSS Statistics Viewer, vous pouvez changer le style des graphiques (plots) en utilisant l'éditeur de graphiques :

1. Double-cliquez sur le graphique dans le Statistics Viewer pour ouvrir l'éditeur de graphiques.
2. Une fois l'**éditeur de graphiques** ouvert, vous pouvez changer le style des éléments en double-cliquant sur l'élément que vous souhaitez modifier (par exemple, une barre, un axe, ou une légende). Cela ouvrira une fenêtre de **propriétés** où vous pourrez ajuster le style, la couleur, la taille, et d'autres paramètres.

5.4.2 Fréquences pour les variables continues

■ Comme vous l'avez vu, les **tableaux de fréquence** affichent des nombres et des pourcentages, ce qui est extrêmement utile lorsque vous travaillez avec des variables qualitatives. Cependant, pour les variables continues, qui peuvent avoir de nombreuses valeurs, les tables de fréquences deviennent moins utiles.

■ Pour exécuter des fréquences pour des variables continues, procédez comme suit :

1. **Annulez le fractionnement des données.**
2. Choisissez **Analyse → Statistiques descriptives → Fréquences.**
3. Sélectionnez les variables **Weight**, et **Bloodsugar**, et placez-les dans la zone Variable(s).
4. Décochez la case **Afficher les tables de fréquences**, comme illustré dans la Figure 5.8 ci-dessous.



FIGURE 5.8 – Boîte de dialogue Fréquences

5. Cliquez sur le bouton **Statistiques.**
6. Dans la section **Tendance centrale**, cochez les cases **Moyenne**, **Médiane** et **Mode**. Dans la section **Dispersion**, sélectionnez **Ecart type**, **Variance**, **Minimum et Maximum.**
7. Cliquez sur **Poursuivre.**
8. Cliquez sur le bouton **Graphiques.**

9. Sélectionnez le bouton radio **Histogrammes** et cochez la case **Afficher la courbe gaussienne sur l'histogramme**, comme illustré dans la Figure 5.9.




FIGURE 5.9 – Boîte de dialogue Fréquences :Graphiques

Fréquences

Statistiques			
		Weight	Bloodsugar
N	Valide	7	7
	Manquant	0	0
Moyenne		87,3143	1,7286
Médiane		88,0000	1,4000
Mode		45,00 ^a	1,20
Ecart type		42,49029	,99115
Variance		1805,425	,982
Minimum		45,00	,60
Maximum		175,00	3,60



a. Présence de plusieurs modes. La plus petite valeur est affichée.

Histogramme




FIGURE 5.10 – Résultat de l'analyse

10. Cliquez sur **Poursuivre**, puis sur **OK** : SPSS exécute la procédure des fréquences et calcule les statistiques récapitulatives et l'histogramme que vous avez demandés.
11. La sortie résultante, illustrée dans la Figure 5.10.

5.4.3 Résumer des variables continues avec la procédure descriptive

■ La procédure descriptive fournit un résumé succinct de diverses statistiques et le nombre de cas avec des valeurs valides pour chaque variable incluse dans le tableau.

■ Pour utiliser la procédure des descriptifs, procédez comme suit :

1. Choisissez **Analyse → Statistiques descriptives → Descriptives** : la boîte de dialogue Descriptives s'affiche.
2. Sélectionnez les variables **Weight**, et **Bloodsugar**, et placez-les dans la zone Variable(s).
3. Cliquez sur **OK** : SPSS exécute la procédure descriptive et calcule les statistiques récapitulatives comme indiqué ci-dessous (Figure 5.11).

Statistiques descriptives

	N	Minimum	Maximum	Moyenne	Ecart type
Weight	7	45,00	175,00	87,3143	42,49029
Bloodsugar	7	,60	3,60	1,7286	,99115
N valide (liste)	7				

FIGURE 5.11 – Résultat de statistiques descriptives

5.5 Conclusion

Dans ce chapitre, nous avons exploré différentes méthodes d'analyse des données biomédicales en utilisant SPSS, en mettant l'accent sur les variables qualitatives et continues. Ces approches ont permis de résumer les données de manière systématique, tout en s'adaptant aux spécificités des variables étudiées.

L'utilisation des statistiques descriptives illustrent la puissance de SPSS pour organiser et analyser les données biomédicales de manière efficace. En mettant en évidence l'importance d'une méthodologie rigoureuse et adaptée, ce chapitre fournit des bases solides pour mener des analyses exploratoires, essentielles pour identifier des tendances, des corrélations ou des différences significatives.

Chapitre 6

Analyse des Relations entre les Variables Statistiques

6.1 Introduction

L'analyse des données biomédicales peut être utilisée pour étudier les relations entre les variables dans divers contextes, comme l'étude des facteurs de risque d'une maladie ou l'évaluation de l'efficacité d'un traitement médical. L'analyse des relations entre les variables consiste à examiner l'association ou la corrélation entre différentes variables, qui peut être catégorique ou continue. Des méthodes statistiques telles que les tableaux croisés et l'analyse de régression peuvent être utilisées pour identifier et quantifier les relations entre les variables qualitatives et continues, respectivement. De plus, l'analyse de corrélation peut être utilisée pour identifier la force et la direction de la relation entre deux variables continues. En comprenant les relations entre les variables, les chercheurs peuvent mieux comprendre les facteurs sous-jacents qui contribuent à un résultat ou à un phénomène particulier et prendre des décisions éclairées sur la base de leur analyse.

6.2 Collection de Données dans SPSS

1. Télécharger le fichier de données SPSS appelé "**DataSPSS6.sav**" sur : <https://aboulesnane.net/wp-content/datafiles/DataSPSS6.sav>
2. Les données contiennent cinq variables nommées : Patient, Weight, Bloodsugar, LungCancer, et Smoking (voir la Figure 6.1).
 - (a) La Variable "**Patient**" est une variable de type **Chaîne**.
 - (b) La Variable "**Weight**" est une variable quantitative continue de type Numérique.
 - (c) La Variable "**Bloodsugar**" est une variable quantitative continue de type Numérique.
 - (d) Les valeurs possibles pour la variable qualitative "**LungCancer**" : 0=Non et 1=Oui.
 - (e) Les valeurs possibles pour la variable qualitative "**Smoking**" : 1=Non , 2=Parfois, 3=Beaucoup.

6.3. Prétraitement des données dans SPSS

	Patient	Weight	Bloodsugar	LungCancer	Smoking
1	P1	63,00	1,20	1	2
2	P2	90,20	1,70	1	3
3	P3	88,00	1,40	0	2
4	P4	45,00	,60	1	3
5	P5	90,00	2,40	0	2
6	P6	175,00	3,60	0	1
7	P7	60,00	1,20	1	2
8	P8	120,00	1,92	0	1
9	P9	55,00	,70	0	1
10	P10	160,00	4,62	1	3

FIGURE 6.1 – Fichier de données SPSS

6.3 Prétraitement des données dans SPSS

■ Les données des patients ont été triées en fonction de leurs valeurs de poids (**Weight**). (voir section 4.5).

Le résultat du tri est :

	Patient	Weight	Bloodsugar	LungCancer	Smoking
1	P4	45,00	,60	1	3
2	P9	55,00	,70	0	1
3	P7	60,00	1,20	1	2
4	P1	63,00	1,20	1	2
5	P3	88,00	1,40	0	2
6	P5	90,00	2,40	0	2
7	P2	90,20	1,70	1	3
8	P8	120,00	1,92	0	1
9	P10	160,00	4,62	1	3
10	P6	175,00	3,60	0	1

FIGURE 6.2 – Résultat après le tri

6.4 Distributions Statistiques à Deux Caractères

6.4.1 Relations entre variables catégorielles (qualitatives)

L'un des moyens les plus courants d'analyser les données consiste à utiliser des tableaux croisés. Comme mentionné, vous utilisez un tableau croisé lorsque vous souhaitez étudier la relation entre deux ou plusieurs variables catégorielles. Par exemple, vous voudrez peut-être examiner l'impact (la relation) de la cigarette sur le cancer du poumon.

Analyse des Relations entre les Variables Statistiques

	Variables		
	Indépendantes		
	Variables	Qualitatives	Quantitative
Variables Dépendantes	Qualitatives	Tableaux Croisés, Tests Non Paramétriques	Regression Logistique, Analyse Discriminante
	Quantitative	T-Test, ANOVA	Corrélation, Régression Linéaire

TABLE 6.1 – Analyses des relations statistiques

Voici comment effectuer un tableau croisé à partir de nos données (entre la variable **LungCancer** et **Smoking**) :

1. Choisissez **Analyser → Statistiques descriptives → Tableaux croisés** :

La boîte de dialogue Tableaux croisés s'affiche.

Bien que vous puissiez placer les variables dans les zones Lignes ou Colonnes, il est habituel de placer la variable indépendante dans la colonne du tableau croisé. Dans les analyses bivariées, la variable indépendante est celle qui, en théorie, exerce une influence sur l'autre variable, appelée variable dépendante.

La variable indépendante dans cette étude est l'acte de fumer, car on affirme que fumer a un impact direct sur le développement du cancer du poumon :

2. Sélectionnez la variable **LungCancer** et placez-la dans la zone Ligne(s).
3. Sélectionnez la variable **Smoking** et placez-la dans la zone Column(s), comme illustré à la Figure ci-dessous (Figure 6.3).





FIGURE 6.3 – Boîte de dialogue Tableaux croisés

6.4. Distributions Statistiques à Deux Caractères

4. Cliquez sur le bouton **Cellules** : sélectionnez les pourcentages de ligne, les pourcentages de colonne ou les deux.



5. Cliquez sur Poursuivre, puis sur **OK**.
6. La sortie résultante, illustrée dans les figures ci-dessous (Figure 6.4).

→ Tableaux croisés

Récapitulatif de traitement des observations

	Observations					
	Valide		Manquant		Total	
	N	Pourcentage	N	Pourcentage	N	Pourcentage
LungCancer * Smoking	10	100,0%	0	0,0%	10	100,0%

Tableau croisé LungCancer ^ Smoking

			Smoking			Total
			Non	Parfois	Beaucoup	
LungCancer	Non	Effectif	3	2	0	5
		% dans Smoking	100,0%	50,0%	0,0%	50,0%
	Oui	Effectif	0	2	3	5
		% dans Smoking	0,0%	50,0%	100,0%	50,0%
Total		Effectif	3	4	3	10
		% dans Smoking	100,0%	100,0%	100,0%	100,0%

FIGURE 6.4 – Résultat des tableaux croisés

6.4.2 Relations entre variables quantitatives

Les deux techniques statistiques les plus couramment utilisées pour analyser les relations entre les variables continues sont la corrélation de Pearson et la régression linéaire.

De nombreuses personnes utilisent le terme corrélation pour désigner l'idée d'une relation entre des variables dans un modèle. En d'autres termes, les variables sont corrélées entre elles parce que les changements d'une variable affectent l'autre.

Alors que la corrélation essaie simplement de déterminer si deux variables sont liées, la régression linéaire va encore plus loin et tente de prédire les valeurs d'une variable en fonction d'une autre variable.

❖ Exécution de la procédure bivariée

Le coefficient de corrélation de Pearson est une mesure de la mesure dans laquelle il existe une relation linéaire (ligne droite) entre deux variables. Il a des valeurs comprises entre -1 et $+1$, de sorte que plus la valeur absolue est grande, plus la corrélation est forte. Par exemple, une corrélation de $+1$ indique




FIGURE 6.5 – Corrélations Bivariées

que les données tombent sur une ligne droite parfaite inclinée vers le haut (relation positive), et une corrélation de -1 représente les données formant une ligne droite parfaite inclinée vers le bas (relation négative). Une corrélation de 0 indique qu'il n'existe aucune relation linéaire.

Pour tester une corrélation, procédez comme suit :

1. Choisissez **Analyse → Corrélation → Bivarié**. La boîte de dialogue **Corrélations bivariées** s'affiche.
Dans cet exemple, vous étudierez si la glycémie est liée au poids. Notez qu'il n'y a pas de désignation de variables dépendantes et indépendantes. Les corrélations seront calculées sur toutes les paires de variables.
2. Sélectionnez les variables **Weight** et **Bloodsugar** et placez-les dans la zone Variables, comme illustré à la Figure 6.5 ci-dessus.
3. Cliquez sur le bouton **Options** et cochez l'option « **Ecart des produits croisés et covariances** »
4. Cliquez sur **Poursuivre**, puis sur **OK**.

6.4. Distributions Statistiques à Deux Caractères

5. La sortie résultante, illustrée dans la Figure 6.6 ci-dessous.

→ Corrélations

Corrélations

		Weight	Bloodsugar
Weight	Corrélation de Pearson	1	,925**
	Sig. (bilatérale)		,000
	Somme des carrés et produits croisés	17694,596	475,289
	Covariance :	1966,066	52,810
	N	10	10
Bloodsugar	Corrélation de Pearson	,925**	1
	Sig. (bilatérale)	,000	
	Somme des carrés et produits croisés	475,289	14,927
	Covariance :	52,810	1,659
	N	10	10

Covariance en utilisant la correction de Bessel, où on divise sur N-1

** . La corrélation est significative au niveau 0.01 (bilatéral).

FIGURE 6.6 – Tableau des corrélations

Dans cet exemple, vous avez une très forte corrélation positive (0,925) qui est statistiquement significative entre la glycémie et le poids.

D'une autre manière, du même tableau, nous pouvons calculer le coefficient de corrélation à partir de la matrice de covariance, comme suit :

$$r = \frac{XY \text{ covariance}}{\sqrt{X \text{ variance}} \sqrt{Y \text{ variance}}}$$

$$r = \frac{\left(\frac{\sum (X - \bar{X})(Y - \bar{Y})}{N} \right)}{\sqrt{\frac{\sum (X - \bar{X})(X - \bar{X})}{N}} * \sqrt{\frac{\sum (Y - \bar{Y})(Y - \bar{Y})}{N}}}$$

$$r = \frac{\left(\frac{475,289}{10} \right)}{\sqrt{\frac{17694,596}{10}} * \sqrt{\frac{14,927}{10}}} = 0.925$$

❖ Exécution de la procédure de régression linéaire simple

Les corrélations vous permettent de déterminer si deux variables continues sont linéairement liées l'une à l'autre. L'analyse de régression consiste à prédire le futur (l'inconnu) sur la base de données recueillies dans le passé (le connu). La régression vous permet de quantifier davantage les relations en développant une **équation** afin que vous puissiez prédire, par exemple, la glycémie en fonction de poids corporel du patient.

La régression linéaire est une technique statistique utilisée pour prédire une variable **dépendante continue** à partir d'une ou plusieurs variables **indépendantes continues**.

Puisque nous avons une forte corrélation linéaire entre la glycémie et le poids, nous pouvons effectuer une régression linéaire, comme suit :

1. Sélectionnez **Analyse → Régression → Linéaire**.

La boîte de dialogue Régression linéaire s'affiche. Dans cet exemple, vous souhaitez prédire la glycémie à partir de poids. Vous pouvez placer la variable dépendante, la glycémie (**Bloodsugar**), dans la case **Dépendant** ; il s'agit de la variable pour laquelle vous souhaitez définir une équation de prédiction. Vous pouvez placer la variable prédictive **Weight** dans la zone **Indépendantes** ; c'est la variable que vous utiliserez pour prédire la variable dépendante.

2. Sélectionnez la variable **Bloodsugar** et placez-la dans la zone Dépendant.
3. Sélectionnez la variable **Weight** et placez-la dans la zone indépendantes, comme illustré dans la Figure 6.7.




FIGURE 6.7 – Boîte de dialogue Régression linéaire

6.5. Représentation graphique des données

4. Cliquez sur **OK** : SPSS effectue la régression linéaire (voir Figure 6.8).

➔ Régression

Variables introduites/éliminées^a

Modèle	Variables introduites	Variables éliminées	Méthode
1	Weight ^b	.	Introduire

a. Variable dépendante : Bloodsugar

b. Toutes les variables demandées ont été introduites.

Récapitulatif des modèles

Modèle	R	R-deux	R-deux ajusté	Erreur standard de l'estimation
1	,925 ^a	,855	,837	,51969

a. Prédicteurs : (Constante), Weight

ANOVA^a

Modèle		Somme des carrés	ddl	Carré moyen	F	Sig.
1	Régression	12,767	1	12,767	47,270	,000 ^b
	Résidus	2,161	8	,270		
	Total	14,927	9			

a. Variable dépendante : Bloodsugar

b. Prédicteurs : (Constante), Weight

Coefficients^a

Modèle		Coefficients non standardisés		Coefficients standardisés	t	Sig.
		B	Ecart standard	Bêta		
1	(Constante)	-,608	,405		-1,502	,172
	Weight	,027	,004	,925	6,875	,000

a. Variable dépendante : Bloodsugar

FIGURE 6.8 – Résultat de la régression linéaire

La colonne B contient les coefficients de régression (a : la pente, b : l'ordonnée à l'origine) que vous utiliseriez dans une équation de prédiction. Dans cet exemple, la glycémie peut être prédite avec l'équation suivante :

$$\text{Bloodsugar} = a * \text{Weight} + b$$

$$\text{Bloodsugar} = 0.027 * \text{Weight} - 0.608$$

6.5 Représentation graphique des données

Le menu **Graphiques** dans SPSS comporte trois options principales : **Générateur de graphiques**, **Sélecteur de modèles de représentations graphiques** et

Boîtes de dialogue ancienne version. Ces options sont différentes façons de faire le même travail. Les **Boîtes de dialogue ancienne version** sont les graphiques originaux de SPSS et sont principalement choisies par les personnes qui les utilisent depuis des années et qui trouvent trop difficile de passer à une autre option.

Sélecteur de modèles de représentations graphiques et **Générateur de graphiques** permettent de créer des graphiques de différentes manières. Dans « **Sélecteur de modèles de représentations graphiques** », vous sélectionnez d'abord les variables que vous souhaitez afficher. Sur la base de ces informations, différentes options de graphique sont proposées. **Générateur de graphiques** commence par présenter différents types de graphiques. Après avoir sélectionné un graphique, vous spécifiez les variables que vous utiliserez.

6.5.1 Construire des graphiques à la manière du Générateur de graphiques

SPSS contient **Générateur de graphiques**, qui utilise un affichage graphique pour vous guider à travers les étapes de construction de graphiques. Le programme vérifie continuellement vos actions et bloque l'utilisation de fonctionnalités qui ne sont pas compatibles ou qui ne fonctionneront pas correctement.

A travers un exemple, nous allons voir comment générer un graphe. Supposons que nous voulions tracer la **boîte à moustaches** de la variable « **Bloodsugar** ».

1. Choisissez **Graphiques → Générateur de graphiques**. Un avertissement s'affiche, vous informant qu'avant d'utiliser cette boîte de dialogue, le niveau de mesure doit être défini correctement pour chaque variable de votre graphique. (Nous avons défini le niveau de mesure correct, vous pouvez donc continuer.)
2. Cliquez sur **OK** : la boîte de dialogue **Générateur de graphiques** s'affiche.
3. Assurez-vous que l'onglet **Galerie** est sélectionné : dans la liste "**Choisir parmi**", sélectionnez "**Boîtes à moustaches**" comme type de graphique.
4. Différents types de boîtes à moustaches apparaissent dans la galerie à droite de la liste, comme illustré dans la Figure 6.9 ci-dessous.



FIGURE 6.9 – Générateur de graphiques

5. Sélectionnez et faites glisser « **Boîte à Moustaches : 1D** » vers le panneau d'affichage. L'onglet **Propriétés des éléments** apparaît maintenant

6.5. Représentation graphique des données

à droite du panneau d'aperçu en haut. Cet onglet vous permet de savoir quelles fonctionnalités de l'élément vous pouvez modifier. Par exemple, vous pouvez changer la statistique à afficher ou le style des graphes. Dans cet exemple, vous n'utilisez pas l'onglet **Propriétés des éléments**, alors fermez-le simplement.

6. Dans la liste des variables, sélectionnez la variable **Bloodsugar** et faites-la glisser vers l'étiquette de l'axe Y dans le diagramme. L'affichage graphique à l'intérieur de la fenêtre d'aperçu du graphique ne représente jamais vos données réelles, même après avoir inséré des noms de variables.
7. Cliquez sur le bouton **OK** pour produire le graphique : la sortie résultante, illustrée dans la Figure 6.10 ci-dessous.

➔ GGraph




FIGURE 6.10 – Boîte à Moustaches :1D pour la variable Bloodsugar

6.5.2 Affichage d'une relation linéaire

Les étapes suivantes vous montrent comment construire un nuage de points simple :

1. Choisissez **Graphiques → Générateur de graphiques**.
2. Cliquez sur le bouton **OK** puis le bouton **Réinitialiser**.
3. Dans la liste « **Choisir parmi** », sélectionnez **Dispersion/Points**.
4. Sélectionnez le premier diagramme de nuage de points (Diagramme de dispersion : simple) et faites-le glisser vers le panneau en haut.
5. Dans la liste Variables, sélectionnez **Weight** et faites-le glisser vers le rectangle intitulé X-Axis dans le diagramme.
6. Dans la liste Variables, sélectionnez **Bloodsugar** et faites-le glisser vers le rectangle intitulé Y-Axis dans le diagramme.
7. Cliquez sur **OK** : le graphique dans la Figure 6.11 s'affiche.

➔ **GGraph**




FIGURE 6.11 – Nuage de points de deux variables quantitatives

8. Double-cliquez sur le graphique produit : la boîte de dialogue « **Editeur de graphiques** » s'affiche.
9. Appuyez sur l'icône « **Ajouter une courbe d'ajustement au total** », puis sur le bouton Fermer, et enfin fermez la fenêtre « **Editeur de graphiques** ».

10. La sortie résultante, illustrée dans la Figure 6.12 ci-dessous.

GGraph




FIGURE 6.12 – Droite de régression linéaire

La droite superposée au nuage de points est la meilleure droite qui décrit la relation linéaire de l'équation : $y = 0.03 * x - 0.61$, où y représente **Bloodsugar** et x est le **Weight**.

6.6 Conclusion

Les chercheurs peuvent utiliser SPSS pour étudier les relations entre les variables en analysant à la fois les variables qualitatives et continues. SPSS fournit divers outils et fonctions, tels que la tabulation croisée et l'analyse de corrélation, pour examiner l'association ou la corrélation entre les variables. L'analyse de tableaux croisés peut être utilisée pour identifier les relations entre deux ou plusieurs variables qualitatives, tandis que l'analyse de corrélation peut être utilisée pour déterminer la force et la direction de la relation entre deux variables continues. De plus, l'analyse de régression peut être utilisée pour examiner la relation entre une variable dépendante et une ou plusieurs variables indépendantes, et pour créer un modèle qui prédit les valeurs de la variable dépendante en fonction des variables indépendantes. En utilisant ces fonctions et outils, les chercheurs peuvent étudier les relations entre les variables dans leurs données biomédicales et prendre des décisions éclairées en fonction de leur analyse.

Chapitre 7

Distributions de Probabilité avec SPSS

7.1 Introduction

SPSS comprend de nombreuses distributions standard intégrées couramment utilisées dans l'analyse statistique et la construction de modèles, qui peuvent remplacer les tableaux statistiques traditionnels. Parmi la multitude de distributions disponibles, les distributions **binomiale** et **normale** se dressent comme des piliers, offrant des insights inestimables dans les données **dis-crètes** et **continues**, respectivement.

Les trois éléments fondamentaux qui peuvent être calculés pour une distribution statistique sont :

1. **Fonction de densité de probabilité (PDF)** : La fonction PDF pour les distributions binomiales et normales est utilisée pour décrire la probabilité ou la vraisemblance d'observer des résultats ou des valeurs spécifiques au sein des distributions respectives.
2. **Fonction de distribution cumulative (CDF)** : elle représente la probabilité qu'une variable aléatoire prenne une valeur inférieure ou égale à une valeur donnée. En d'autres termes, le CDF est la somme cumulée des probabilités jusqu'à un certain point.
3. **Fonction de distribution inverse (IDF)** : elle est également appelée fonction quantile et fournit la valeur d'une variable aléatoire qui correspond à une probabilité donnée. En d'autres termes, l'IDF donne la valeur de x telle que la probabilité d'obtenir une valeur inférieure ou égale à x soit égale à une probabilité donnée.

Pour toutes les distributions implémentées dans SPSS, il existe une fonction pour chacun des trois éléments énumérés ci-dessus. La convention de dénomination de ces fonctions consiste à préfixer le nom par "Pdf" pour la fonction de densité de probabilité (PDF), "Cdf" pour la fonction de distribution cumulative (CDF) et "Idf" pour la fonction de distribution cumulative inverse (IDF).

7.2 Distribution Binomiales (distribution discrète finie)

Pour calculer les probabilités binomiales de la forme $P(x | n, p)$, vous devez créer une colonne de données contenant les valeurs de x que vous souhaitez utiliser. Une fois que vous avez cette colonne, vous pouvez l'utiliser comme entrée dans la formule de probabilité binomiale pour calculer les probabilités pour chaque valeur donnée.

Pour effectuer les probabilités binomiales, nous utilisons les fonctions SPSS suivantes :

► *La fonction de densité de probabilité* : calcule la probabilité que la variable aléatoire binomiale prenne une valeur particulière x (**=x**), compte tenu du nombre d'essais n et de la probabilité de succès p .

$$PDF.BINOM(x, n, p)$$

► *La fonction de distribution cumulative binomiale* : calcule la probabilité que la variable aléatoire binomiale prenne une valeur **inférieure ou égale à x**, compte tenu du nombre d'essais n et de la probabilité de succès p .

$$CDF.BINOM(x, n, p)$$

Où x est le nombre de succès, n est la taille de l'échantillon, et p représente la probabilité de succès.

Exemple : Quelle est la probabilité d'obtenir k faces avec une pièce lancée n fois, ou avec n pièces lancées simultanément ?

- Calculer $P(X=k)$ avec $k=0, 1, 2, 3, 4, 5$ et $n=5$.
- Représenter graphiquement les probabilités obtenues.

Procédure SPSS pour les probabilités binomiales :

1. Dans l'onglet Vue des variables, créez une nouvelle variable d'échelle (discrète) nommée **k**.
2. Tapez le nombre de succès de 0 à 5 dans la variable **k**.
3. Choisissez **Transformer → Calculer la variable** : la boîte de dialogue **Calculer la variable...** apparaît.
4. Dans le groupe de fonctions, sélectionnez **PDF et PDF non centré →** Dans la zone fonctions et variables spéciales, double-cliquez sur la fonction **Pdf.Binom**, et la formule apparaîtra dans la zone d'expression numérique, voir Figure 7.1.



FIGURE 7.1 – Boîte de dialogue : Calculer la variable

5. Donnez la variable cible le nom : **"Prob"** et tapez l'expression **PDF.BINOM(k,5,0.5)** → Cliquez sur **OK**.
6. En conséquence, une nouvelle variable apparaîtra avec des probabilités binomiales, voir la Figure 7.2 (définir le nombre décimal sur 4 pour la nouvelle variable **Prob**).

	k	Prob
1	0	,0313
2	1	,1563
3	2	,3125
4	3	,3125
5	4	,1563
6	5	,0313

FIGURE 7.2 – Résultat après le calcul des probabilités binomiales

7. Choisissez **Graphiques** → **Générateur de graphiques** → Cliquez sur le bouton **OK**.
8. Dans la liste « **Choisir parmi** », sélectionnez **Courbe**.
9. Sélectionnez le premier diagramme de nuage de points (**Diagramme en Lignes : simple**) et faites-le glisser vers le panneau en haut.
10. Dans la liste Variables, sélectionnez **k** et faites-le glisser vers le rectangle intitulé X-Axis dans le diagramme.
11. Dans la liste Variables, sélectionnez **Prob** et faites-le glisser vers le rectangle intitulé Y-Axis dans le diagramme.

7.3. Distribution Normale (distribution continue)

12. Cliquez sur **OK** : le graphique dans la Figure 7.3 s'affiche.




FIGURE 7.3 – Représentation graphique des probabilités

7.3 Distribution Normale (distribution continue)

La distribution normale est largement considérée comme la distribution de probabilité la plus importante dans les statistiques, car elle décrit avec précision de nombreux phénomènes naturels, tels que le poids, l'âge, les tempêtes, les inondations et autres.

7.3.1 Probabilités Normales

Pour effectuer les probabilités normales, nous utilisons la fonction SPSS suivante :

$$CDF.NORMAL(x, m, d)$$

Où x représente la quantité donnée, m représente la moyenne et d est l'écart type.

Exemple : Une variable aléatoire continue X suit la distribution normale avec une moyenne $m = 50$ et une variance $\sigma^2 = 100$. Trouvez la probabilité que :

1. $P(X < 44)$?
2. $P(29 < X < 53)$?
3. $P(35 < X < 43)$?
4. $P(X < 63)$?
5. $P(X > 37,2)$?
6. $P(58,1 < X < 69,4)$?

Distributions de Probabilité avec SPSS

Procédure SPSS pour calculer la probabilité à partir de la distribution normale :

1. Dans l'onglet Vue des variables, créez une nouvelle variable d'échelle (continue) nommée *Prob* avec quatre chiffres derrière la virgule (Décimal=4).
2. Tapez le chiffre 0 dans la cellule **1 :Prob**.
3. Choisissez **Transformer → Calculer la variable** : la boîte de dialogue **Calculer la variable**... apparaît.
4. Dans le groupe de fonctions, sélectionnez **CDF et CDF non centré** → Dans la zone fonctions et variables spéciales, double-cliquez sur la fonction **Cdf.Normal**, et la formule apparaîtra dans la zone d'expression numérique, voir Figure 7.4.




FIGURE 7.4 – Boîte de dialogue : Calculer la variable

- (a) **Pour $P(X < 44)$** : Donnez la variable cible le nom : "**Prob**" et tapez l'expression **CDF.NORMAL (44,50,10)** → Cliquez sur **OK** → La cellule **1 :Prob** affichera une probabilité de 0,2743.
- (b) **Pour $P(29 < X < 53)$** : Donnez la variable cible le nom : "**Prob**" et tapez l'expression **CDF.NORMAL(53,50,10)-CDF.NORMAL(29,50,10)** → Cliquez sur **OK** → La cellule **1 :Prob** affichera une probabilité de 0,6000.
- (c) **Pour $P(X > 37,2)$** : Donnez la variable cible le nom : "**Prob**" et tapez l'expression **1-CDF.NORMAL (37.2,50,10)** → Cliquez sur **OK** → La cellule **1 :Prob** affichera une probabilité de 0,8997.

7.3.2 Centiles Normaux

Étant donné une probabilité, pour déterminer quelle valeur correspond à une probabilité unilatérale à gauche, nous utilisons la fonction SPSS suivante :

$$IDF.NORMAL(p, m, d)$$

Où p représente la probabilité donnée, m représente la moyenne et d est l'écart type.

Dans $P(X \leq x) = p$, où X est une variable aléatoire avec une distribution normale et p est une probabilité donnée, la fonction `IDF.NORMAL` aide à trouver la valeur de x qui correspond à une probabilité ou à un centile spécifique dans une distribution normale.

Exemple : Les scores au test IELTS ces dernières années suivent approximativement la distribution $N(504, 111)$. Quelle note un étudiant doit-il obtenir pour se classer parmi les 10% de tous les étudiants qui passent l'IELTS ?

Procédure SPSS pour les centiles Normaux :

1. Dans l'onglet vue des variables, créez trois nouvelles variables d'échelles (continues) nommées **Prob**, **Moyenne** et **Sd**. Changez le nombre de décimales pour **Moyenne** et **Sd** par 0.
2. Allez dans l'onglet vue de données → Tapez 0,90 sous la variable **Prob** dans la première cellule. Dans une distribution normale, qui est symétrique autour de sa moyenne, la zone sous la courbe à gauche d'un certain point représente la probabilité cumulative jusqu'à ce point. Par conséquent, si nous voulons trouver le score qui correspond aux 10 % supérieurs, nous cherchons essentiellement un score qui laisse 90 % de la distribution en dessous de lui (Voir la Figure 7.5).
3. Saisissez 504 sous la variable **Moyenne**. Tapez 111 sous la variable **Sd**.
4. Choisissez **Transformer → Calculer la variable** : la boîte de dialogue **Calculer la variable**... apparaît.
5. Dans le groupe de fonctions, sélectionnez **Fonctions de distribution inverse** → Dans la zone fonctions et variables spéciales, double-cliquez sur la fonction **Idf.NORMAL**, et la formule apparaîtra dans la zone d'expression numérique.




FIGURE 7.5 – La zone sous la courbe à gauche de x ($p(X < x) = 0,9$) [uiowa, 2024].

6. Donnez la variable cible le nom : "**RES**" et tapez l'expression **IDF.NORMAL(Prob,Moyenne,Sd)**, voir Figure 7.6.




FIGURE 7.6 – Boîte de dialogue : Calculer la variable

7. Cliquez sur **OK** → La cellule **RES** affichera une valeur de 646,25, voir la Figure 7.7.

	Prob	Moyenne	Sd	RES
1	,90	504	111	646,25

FIGURE 7.7 – Résultat après l'application de la fonction IDF.NORMAL

Donc, un étudiant doit obtenir un score d'environ 646,25 ou plus pour se classer parmi les 10 % des meilleurs étudiants passant l'IELTS.

7.3.3 Estimation par Intervalles de confiance

Pour estimer la moyenne d'une population avec un intervalle de confiance, vous devez suivre ces étapes :

1. Déterminez la taille de l'échantillon (n) et la moyenne de l'échantillon ($\bar{x}$) des données.
2. Choisissez un niveau de confiance (généralement 95% ou 99%) et déterminez la valeur z correspondante pour ce niveau de confiance. Par exemple, un niveau de confiance de 95% correspondrait à une valeur z de 1,96.
3. Calculez l'erreur type de la moyenne (SEM), qui est l'écart type de l'échantillon (s) divisé par la racine carrée de la taille de l'échantillon (n) : $SEM = s/\sqrt{n}$.
4. Calculez la marge d'erreur (ME), qui est le produit de la SEM et de la valeur z : $ME = z * SEM$.
5. Calculez les bornes inférieure et supérieure de l'intervalle de confiance en soustrayant et en ajoutant la marge d'erreur à la moyenne de l'échantillon : Borne inférieure = $\bar{x} - ME$, Borne supérieure = $\bar{x} + ME$.

7.3. Distribution Normale (distribution continue)

Par exemple, supposons que nous voulions estimer la taille moyenne d'une population sur la base d'un échantillon de 100 personnes, avec une moyenne d'échantillon de 68 pouces et un écart type d'échantillon de 3 pouces. Nous choisissons un niveau de confiance de 95%.

$n = 100$, $\bar{x} = 68$ pouces

Pour un niveau de confiance de 95%, $z = 1,96$.

$SEM = s/\sqrt{n} = 3/\sqrt{100} = 0,3$ pouces

$ME = z * SEM = 1,96 * 0,3 = 0,588$ pouces

Limite inférieure = $68 - 0,588 = 67,412$ pouces, Limite supérieure = $68 + 0,588 = 68,588$ pouces

Par conséquent, nous pouvons dire avec une confiance de 95% que la taille moyenne de la population se situe entre 67,412 et 68,588 pouces sur la base de nos données d'échantillon.

Procédure SPSS pour l'estimation de μ avec un intervalle de confiance de 95% :

1. Dans l'onglet vue des variables, créez trois nouvelles variables d'échelles (continues) nommées **xbar**, **sigma** et **n** (voir Figure 7.8 ci-dessous).




FIGURE 7.8 – Vue des variables

2. Dans l'onglet vue des données, sous la variable **xbar**, tapez « 68 » pour la moyenne de l'échantillon, sous la variable **sigma**, tapez « 3 » pour l'écart type de la population, et sous la variable **n**, tapez « 100 » pour la taille de l'échantillon.
3. Choisissez **Transformer → Calculer la variable** : la boîte de dialogue **Calculer la variable...** apparaît.
4. Donnez la variable cible le nom : **lowerbound** et tapez l'expression **xbar - 1.96 * sigma/SQRT(n)**, voir Figure 7.9.




FIGURE 7.9 – Boîte de dialogue : Calculer la variable

5. Cliquez sur **OK**.
6. Répétez les étapes 3 à 5, en utilisant **upperbound** et l'expression : **xbar + 1,96 * sigma/SQRT(n)**.
7. Cliquez sur **OK** → Les cellules **lowerbound** et **upperbound** afficheront les valeurs de **67,41** et **68,59**, respectivement, voir la Figure 7.10.

	xbar	sigma	n	lowerbound	upperbound
1	68,00	3,00	100,00	67,41	68,59

FIGURE 7.10 – Résultat de l'estimation

7.4 Conclusion

En conclusion, l'intégration des fonctions de densité de probabilité (PDF), de distribution cumulative (CDF) et de distribution inverse (IDF) de SPSS pour les distributions binomiales et normales a grandement facilité l'analyse et l'interprétation des données. Ces puissants outils statistiques ont permis une exploration approfondie de la probabilité de résultats ou de valeurs spécifiques au sein des distributions, facilitant ainsi la formulation de conclusions pertinentes. De plus, maîtriser l'estimation de la moyenne en utilisant des intervalles de confiance à l'aide de SPSS renforce notre capacité à exploiter efficacement les fonctionnalités du logiciel, améliorant ainsi la précision et la fiabilité de nos analyses statistiques.