

Chapitre 5 : L'échantillonnage et théorie de l'estimation

1. Théorie élémentaire de l'échantillonnage

L'échantillonnage est une sélection d'une fraction d'individus à partir d'une population plus vaste de référence afin de réaliser un sondage. Seulement, qu'est ce qu'un 'Sondage'?

Définition : Un sondage est une opération statistique amenant à étudier une fraction d'un ensemble ou échantillon pour obtenir une information sur l'ensemble total.

But : Le recours à un échantillon est nécessaire pour l'une des raisons suivantes :

- ▶ L'information totale est trop volumineuse (dossiers administratifs de remboursement de Sécurité Sociale)
- ▶ La méthode de collecte est destructive (contrôle de qualité des seringues, aiguilles, médicaments...)
- ▶ L'information est urgente (certaines opérations de surveillance épidémiologique, sondage d'opinion). En effet, il est impossible de rejoindre toute la population dans un court laps de temps ou l'interroger à fond.

L'échantillonnage peut être :

- ▶ Exhaustif (ou sans remise) : prélèvement de n individus en une seule fois, ou successivement sans remise, dans ce cas la composition de l'urne est modifiée à chaque tirage (les tirages ne sont pas indépendants)
- ▶ Non exhaustif (ou avec remise) : lorsque chaque individu prélevé est remis dans la population avant le tirage de l'individu suivant (les tirages sont indépendants).

Remarque. En pratique c'est le tirage sans remise qui est le plus fréquent (le bon sens l'exige malgré quelques exceptions).

Exemples :

- La réponse d'un groupe de 1000 personnes choisies avec une certaine méthode peut nous renseigner, avec une précision remarquable, sur l'intention de vote de la population entière
- Une certaine façon de procéder dans la prise de quelques poissons dans un lac nous renseigne sur la quantité totale des poissons qui s'y trouvent.
- De même, une certaine façon de choisir quelques épis dans un champ de blé apporte l'information sur le champ en entier. Remarquons que nous suivons ce procédé, sans nous en rendre compte, dans la vie de tous les jours. En effet,
 - Au marché, nous tâtons 3 ou 4 pêches pour voir si cette marchandise (toute) est bien mûre
 - Si nous demandons à un Algérien ce qu'il pense des Tunisiens il dira : 'c'est de braves gens !'. Est ce qu'il les connaît tous ? Non, seulement quelques uns ! Mais il tire la conclusion sur des millions !

Nous constatons ainsi qu'il n'est pas nécessaire de faire appel à toute la population pour mener une enquête. Un échantillon suffit amplement car il présente des avantages intéressants et souvent insoupçonnés. Ainsi, c'est de la manière de faire jouer le hasard dans le choix des éléments de l'échantillon que nous rendons possible la déduction de l'information sur le tout.

II. Théorie de l'estimation

1. Intervalle de confiance et de pari d'un pourcentage

1.1 Distribution d'échantillonnage

Exemple introductif : Soit une population de 5000 enfants de 3 ans dont 2000 ont déjà reçu le vaccin B.C.G. et 3000 ne l'ont pas reçu : on peut désigner un tel univers par p (vaccinés)=0,4 et q (non vaccinés)=0,6. Si l'on tire des échantillons de cette population, et si ces échantillons sont de taille n , nous savons que le nombre des vaccinés dans chaque échantillon tiré pourra varier entre 0 et n ; les probabilités d'occurrence de chaque valeur de cette variable "nombre de vaccinés", entre 0 et n , sont déduites de la loi binomiale $B(n,p)$. Par exemple la probabilité de tirer un échantillon où tous les n enfants soient vaccinés est $p^n=0,4^n$; celle de tirer un échantillon où aucun des n enfants ne soit vacciné est $q^n=0,6^n$; Pour toutes les situations intermédiaires x entre 0 et n , on évalue la probabilité à l'aide de la formule

$$C_n^x p^x q^{n-x}.$$

Définition : la **distribution d'échantillonnage** est la distribution théorique donnant les probabilités respectives, selon le nombre de succès des divers échantillons de taille n tirés d'un univers défini par p et $q=1-p$.

Dans notre exemple, la distribution d'échantillonnage est la loi binomiale et d'après cette loi :

- l'espérance mathématique, ou moyenne est $x=n \times p=0,4 \times n$

- l'écart-type $s=\sqrt{np(1-p)}=n \times 0,4 \times 0,6$

Si la taille des échantillons est assez grande, pour des p et q qui ne sont pas trop petits, cette distribution binomiale tend vers une distribution de Laplace-Gauss. Ceci est vrai pour $npq > 20$ (ou $np > 20$ ou $nq > 20$). Comme dans notre cas $p < q$ ceci est vrai si $np > 20$, soit $n > 20/p$, soit $n > 50$.

1.2 Intervalle de confiance d'une proportion (d'un pourcentage)

L'idée directrice est la suivante :

On souhaite associer à une valeur observée un intervalle appelé INTERVALLE DE CONFIANCE qui ait « de bonnes chances » de contenir la valeur « vraie » p (dans l'exemple introductif $p=0,4$) de la proportion. Que signifie de « bonnes chances » ? Si l'on effectue un grand nombre de fois l'expérience - chaque expérience produisant un pourcentage observé

- on construit autant d'intervalles de confiance. On voudrait qu'un grand nombre de ces intervalles contienne la valeur « vraie » p . Par exemple que 95 % des intervalles en gros contiennent p . On parlera alors d'intervalle de confiance DE NIVEAU 0,95 ou d'intervalle de confiance AU RISQUE 0,05. On considérera généralement des intervalles de confiance de niveau $1-\alpha$. La valeur α sera alors le risque - ou la probabilité - pour qu'un intervalle de confiance ne contienne pas la proportion « vraie » p .

DE FACON GENERALE, L'INTERVALLE DE CONFIANCE AU RISQUE α D'UNE VALEUR QUE L'ON CHERCHE A ESTIMER EST UN INTERVALLE QUI CONTIENT AVEC UNE PROBABILITE $1 - \alpha$ LA

VALEUR CHERCHÉE ; IL S'AGIT D'UN INTERVALLE QUE L'ON DEVRA ÊTRE EN MESURE DE CONSTRUIRE À L'ISSUE D'UNE EXPERIENCE PORTANT SUR UN ECHANTILLON.

Comment construire de tels intervalles ?

Pour répondre à cette question nous n'allons considérer ici que le cas de grands échantillons.

En

pratique l'intervalle de confiance d'un pourcentage est déterminé par les formules suivantes :

- au taux de sécurité de 95%

$$IC = \left[p_{ob} - 1,96\sqrt{\frac{p_{ob}(1-p_{ob})}{n}}, p_{ob} + 1,96\sqrt{\frac{p_{ob}(1-p_{ob})}{n}} \right]$$

- Au taux de sécurité de 99%

$$IC = \left[p_{ob} - 2,58\sqrt{\frac{p_{ob}(1-p_{ob})}{n}}, p_{ob} + 2,58\sqrt{\frac{p_{ob}(1-p_{ob})}{n}} \right]$$

Exemple : Dans une école de 1000 élèves un sondage sur une classe de 35 élèves a permis de constater que 7 d'entre eux avaient une légère infection contagieuse. Estimer la proportion d'enfant atteints dans l'école au risque de 5%.

donc on peut appliquer l'approximation normale. L'intervalle de confiance de la proportion au taux de sécurité de 95% est :

1.3 Intervalle de confiance d'une moyenne (Cas de grands échantillons ($n > 30$))

Nous disposons d'un échantillon de taille $n > 30$, de moyenne m et d'écart-type σ_{ech} connus. La moyenne de la population M est inconnue. L'intervalle de confiance de M est déterminé par les formules suivantes :

- au taux de sécurité de 95%

$$M \in \left[m - 1,96\frac{\sigma_{ech}}{\sqrt{n-1}}, m + 1,96\frac{\sigma_{ech}}{\sqrt{n-1}} \right]$$

- au taux de sécurité de 99%

$$M \in \left[m - 2,58\frac{\sigma_{ech}}{\sqrt{n-1}}, m + 2,58\frac{\sigma_{ech}}{\sqrt{n-1}} \right]$$