


TP4. Prétraitement des Données dans SPSS

1. Navigation dans le SPSS Visualiseur (Viewer)

Lorsque vous exécutez une analyse, produisez un graphique ou même l'enregistrement d'un fichier, **la fenêtre SPSS Statistics Viewer** apparaît automatiquement pour afficher ce que vous avez créé.



- Le volet de plan, sur la gauche, contient un aperçu de toutes les informations stockées dans le Viewer.
- Le volet de contenu, à droite, contient les tableaux statistiques, les graphiques et les textes.
- Pour masquer un objet dans le volet de contenu, il faut:
 - ✓ Sélectionnez l'objet (table, graphe..) depuis le volet de plan ou le volet de contenu.
 - ✓ Cliquez sur l'icône du *livre* dans la barre d'outils. 
 - ✓ Pour afficher à nouveau cet objet, appuyez sur l'icône 

Masquer des éléments sans les supprimer permet à l'utilisateur de se concentrer plus facilement sur les résultats qui l'intéressent tout en conservant tous les résultats.

2. Jouer avec les données dans SPSS

	Patient	Weight	Bloodsugar	Sexe	Bloodgroup
1	P1	53,0	1,2	1	1
2	P2	-99,0	1,5	1	3
3	P3	88,0	1,4	2	2
4	P4	45,0	,6	1	4
5	P5	90,0	2,4	2	2
6	P6	175,0	3,6	2	1



- Créer un nouveau fichier de données SPSS appelé « **Tp4.sav** ».
- Les données doivent contenir cinq variables nommées : Patient, Weight, Bloodsugar, Sexe, et Bloodgroup (voir la figure ci-dessus).

- c) La Variable « **Patient** » est une variable de type **Chaîne**.
- d) La Variable « **Weight** » est une variable quantitative continue de type **Numérique**.
 - Pour la variable **Weight**, on remplace les valeurs manquantes par le nombre -99 (voir sous-section II.1.7 dans TP3).
- e) La Variable « **Bloodsugar** » est une variable quantitative continue de type **Numérique**.
- f) Entrez les valeurs possibles pour la variable qualitative « **Sexe** » : 1=Homme et 2=Femme.
- g) Entrez les valeurs possibles pour la variable qualitative « **Bloodgroup** » : 1=AB , 2=A, 3=B et 4=O.

2.1 Remplacement des valeurs manquantes

Afin de remplacer les valeurs manquantes par des valeurs acceptables, nous utiliserons des paramètres de position centrale tels que la moyenne, la médiane, le mode...etc. Par exemple, dans la variable **Weight** de nos données, nous avons une valeur manquante représentée par -99. Afin de ne pas perturber la distribution de nos données, nous pouvons remplacer cette valeur par une valeur moyenne de la série. Pour cela :

- a) Choisissez **Transformer** ⇨ **Remplacer les valeurs manquantes**: la boîte de dialogue **Remplacer les valeurs** apparaît.
- b) Passez la variable **Weight** vers la zone «**Nouvelles variables**».
- c) Dans le menu **Méthode**, vous pouvez sélectionner la meilleure méthode utilisée pour remplacer les valeurs manquantes (Interpolation linéaire, Paramètres de position centrale...). Dans notre cas, nous utiliserons **Moyenne série**.
- d) cliquez sur **OK** (voir la figure ci-dessous).




En conséquence, une nouvelle colonne apparaît avec le nom « **Weight_1** » où la valeur -99 est remplacée par la valeur moyenne 90,2.

	Patient	Weight	Bloodsugar	Sexe	Bloodgroup	Weight_1
1	P1	53,0	1,2	1	1	53,0
2	P2	-99,0	1,5	1	3	90,2
3	P3	88,0	1,4	2	2	88,0
4	P4	45,0	,6	1	4	45,0
5	P5	90,0	2,4	2	2	90,0
6	P6	175,0	3,6	2	1	175,0

2.2 Trier les observations

- Choisissez **Données** ⇨ **Trier les observations**: la boîte de dialogue **Trier les observations** s'affiche.
 - Sélectionnez la variable **Weight**.
 - Cliquez sur OK pour trier les données.
- L'ordre dans lequel les données sont affichées n'affecte jamais l'analyse. Vous triez les données uniquement pour mieux voir les informations dans l'éditeur de données.
 - Vous pouvez trier les données par ordre croissant ou décroissant. Par défaut, les données sont triées par ordre **croissant**.
 - Le tri peut être basé sur un ou plusieurs critères.



Note : pour annuler le tri:


- Nous ne pouvons pas annuler le tri des données.
- Une astuce consiste à trier à nouveau les données en fonction de la variable « **Patient** » (répétez la même procédure vue ci-dessus juste nous sélectionnons la variable **Patient** plutôt que **Weight**).

2.3 Fractionnement des données

Parfois, dans les études comparatives, nous divisons les données en plusieurs groupes en fonction de certains critères, puis effectuons nos analyses sur chaque sous-groupe séparément. **Le fractionnement des données** permet de réaliser ce processus.

- Choisissez **Données** ⇨ **Scinder un fichier**: la boîte de dialogue **Fichier scindé** apparaît.
- Sélectionnez le bouton radio **Comparer les groupes**.
- Choisissez **Sexe** comme variable de comparaison et cliquez sur **OK** (voir la figure ci-dessous).

Note: Après ce processus, nous remarquons qu'il n'y a pas de changement significatif, sauf que les données ont été à nouveau organisées en fonction du sexe des patients.



- Choisissez **Analyse** ⇨ **Statistiques descriptives** ⇨ **Fréquences**.
- Choisissez **Bloodgroup** et placez-le dans la case Variable(s).

f) Cliquez sur **OK**: la sortie résultante, illustrée dans la figure ci-dessous, est groupée par **Sexe**.

➔ Fréquences

Statistiques			
Bloodgroup			
Homme	N	Valide	3
		Manquant	0
Femme	N	Valide	3
		Manquant	0

Bloodgroup						
Sexe			Fréquence	Pourcentage	Pourcentage valide	Pourcentage cumulé
Homme	Valide	AB	1	33,3	33,3	33,3
		B	1	33,3	33,3	66,7
		O	1	33,3	33,3	100,0
		Total	3	100,0	100,0	
Femme	Valide	AB	1	33,3	33,3	33,3
		A	2	66,7	66,7	100,0
		Total	3	100,0	100,0	


Notes:

- Pour annuler le fractionnement, vous devez :
 - a) Choisissez **Données** ➔ **Scinder un fichier**.
 - b) Sélectionnez le bouton radio **Analyser toutes les observations, ne pas créer de groupes**, puis cliquez sur le bouton **OK** (ou appuyez sur le bouton **Réinitialiser** ➔ **OK**).
- Le fractionnement peut être basé sur un ou plusieurs critères.


2.4 Sélection des données

2.4.1 Condition logique simple

- a) Choisissez **Données** ➔ **Sélectionner des observations**: la boîte de dialogue Sélectionner les observations apparaît, comme illustré à la figure ci-dessous.
- b) Sélectionnez le bouton radio **Selon une condition logique**, puis cliquez sur le bouton **Si...** : Vous pouvez maintenant spécifier les critères de sélection.



- c) Déplacez la variable **Sexe** de la liste de gauche vers la zone d'expression (en haut à gauche): vous pouvez déplacer la variable soit en la faisant glisser, soit en la sélectionnant puis en cliquant sur le bouton fléché.
- d) Utilisez votre clavier ou le clavier numérique à l'écran pour saisir **=2** dans la zone d'expression.



- e) Cliquez sur **Poursuivre**, puis sur **OK**. La figure ci-dessous montre le résultat final. Les barres obliques sur certains ID de ligne (dans la première colonne) indiquent que les patients (**hommes**) sont ignorés (pour le moment) et que seules les patientes (**femmes**) sont analysées. La variable **filter_\$** est également créée et comprend 0 et 1 pour les cas non sélectionnés et les cas sélectionnés, respectivement.

	Patient	Weight	Bloodsugar	Sexe	Bloodgroup	filter_\$
1	P1	53,0	1,2	1	1	0
2	P2	-99,0	1,5	1	3	0
3	P3	88,0	1,4	2	2	1
4	P4	45,0	,6	1	4	0
5	P5	90,0	2,4	2	2	1
6	P6	175,0	3,6	2	1	1

Pour voir les effets de la sélection :

- a) Choisissez **Analyse** ⇨ **Statistiques descriptives** ⇨ **Fréquences**.
- b) Choisissez **Bloodgroup** et placez-le dans la case Variable(s).
- c) Cliquez sur **OK**: la sortie résultante, illustrée dans la figure ci-dessous, SPSS affiche uniquement les résultats des groupes sanguins des patientes Femmes.

Fréquences

Statistiques

Bloodgroup

N	Valide	3
	Manquant	0

Bloodgroup

		Fréquence	Pourcentage	Pourcentage valide	Pourcentage cumulé
Valide	AB	1	33,3	33,3	33,3
	A	2	66,7	66,7	100,0
	Total	3	100,0	100,0	

2.4.2 Condition logique complexe


P	Q	$P \wedge Q$
T	T	T
T	F	F
F	T	F
F	F	F

Table de vérité de la conjonction
(& : ET)

P	Q	$P \vee Q$
T	T	T
T	F	T
F	T	T
F	F	F

Table de vérité de la disjonction
(| : OU)

- Essayons maintenant de sélectionner des hommes qui ont un poids supérieur ou égal à 50 ou des patients qui ont un groupe sanguin A.
- Taper la condition suivante: **(Sexe = 1 & Weight >= 50) | Bloodgroup = 2**
- Note : Les parenthèses entre les conditions sont très importantes.



Le résultat de la sélection est :

	Patient	Weight	Bloodsugar	Sexe	Bloodgroup	filter_\$
1	P1	53,0	1,2	Homme	AB	Selected
2	P2	-99,0	1,5	Homme	B	Not Selected
3	P3	88,0	1,4	Femme	A	Selected
4	P4	45,0	,6	Homme	O	Not Selected
5	P5	90,0	2,4	Femme	A	Selected
6	P6	175,0	3,6	Femme	AB	Not Selected

Notes:

- Pour annuler la sélection, vous devez :
 - a) Choisissez **Données ⇌ Sélectionner des observations**.
 - b) Sélectionnez le bouton radio **Toutes les observations**, puis cliquez sur le bouton **OK** (ou appuyez sur le bouton **Réinitialiser ⇌ OK**).
- La sélection peut être basée sur un ou plusieurs critères.