

## TP6. Analyse des Relations entre les Variables Statistiques

### 1. La collection de données dans SPSS

|    | Patient | Weight | Bloodsugar | Sexe | Bloodgroup |
|----|---------|--------|------------|------|------------|
| 1  | P1      | 63,00  | 1,20       | 1    | 1          |
| 2  | P2      | 90,20  | 1,70       | 1    | 3          |
| 3  | P3      | 88,00  | 1,40       | 2    | 2          |
| 4  | P4      | 45,00  | ,60        | 1    | 4          |
| 5  | P5      | 90,00  | 2,40       | 2    | 2          |
| 6  | P6      | 175,00 | 3,60       | 2    | 1          |
| 7  | P7      | 60,00  | 1,20       | 1    | 2          |
| 8  | P8      | 120,00 | 1,92       | 1    | 1          |
| 9  | P9      | 55,00  | ,70        | 2    | 4          |
| 10 | P10     | 160,00 | 4,62       | 2    | 3          |

- Créer un nouveau fichier de données SPSS appelé « **Tp6.sav** ».
- Les données doivent contenir cinq variables nommées : Patient, Weight, Bloodsugar, Sexe, et Bloodgroup (voir la figure ci-dessus).
- La Variable « **Patient** » est une variable de type **Chaîne**.
- La Variable « **Weight** » est une variable quantitative continue de type **Numérique**.
- La Variable « **Bloodsugar** » est une variable quantitative continue de type **Numérique**.
- Entrez les valeurs possibles pour la variable qualitative « **Sexe** » : 1=Homme et 2=Femme.
- Entrez les valeurs possibles pour la variable qualitative « **Bloodgroup** » : 1=AB , 2=A, 3=B et 4=O.

### 2. Prétraitement des données dans SPSS

- Triez les données des patients en fonction de leurs valeurs de poids (**Weight**). (voir section 2.2 dans TP4).

### 3. Les distributions statistiques à deux caractères


|  | Variables Independantes |                                           |                                              |
|--|-------------------------|-------------------------------------------|----------------------------------------------|
|  | Variables               | Categorielle                              | Quantitative                                 |
|  | Categorielle            | Tableaux Croises, Tests Non Parametriques | Regression Logistique, Analyse Discriminante |
|  | Quantitative            | T-Test, Analyse de Variance (ANOVA)       | Corrélation, Régression Linéaire             |

### 3.1 Relations entre variables catégorielles (qualitatives)


L'un des moyens les plus courants d'analyser les données consiste à utiliser des tableaux croisés. Comme mentionné, vous utilisez un tableau croisé lorsque vous souhaitez étudier la relation entre deux ou plusieurs variables catégorielles. Par exemple, vous voudrez peut-être examiner la relation entre le sexe et le groupe sanguin. De cette façon, vous pouvez déterminer si le groupe sanguin est également réparti entre les sexes.

Voici comment effectuer un tableau croisé à partir de nos données (entre la variable **Sexe** et **Bloodgroup**) :

- Choisissez **Analyser** ⇒ **Statistiques descriptives** ⇒ **Tableaux croisés** : La boîte de dialogue Tableaux croisés s'affiche.  
Bien que vous puissiez placer les variables dans les zones Lignes ou Colonnes, il est habituel de placer la variable indépendante dans la colonne du tableau croisé.
- Sélectionnez la variable **Sexe** et placez-la dans la zone Ligne(s).
- Sélectionnez la variable **Bloodgroup** et placez-la dans la zone Column(s), comme illustré à la Figure ci-dessous.



- Cliquez sur le bouton Cellules : sélectionnez les pourcentages de ligne, les pourcentages de colonne ou les deux.



- Cliquez sur **Poursuivre**, puis sur **OK**.
- La sortie résultante, illustrée dans les figures ci-dessous.

#### ➔ Tableaux croisés

Récapitulatif de traitement des observations

|                   | Observations |             |          |             |       |             |
|-------------------|--------------|-------------|----------|-------------|-------|-------------|
|                   | Valide       |             | Manquant |             | Total |             |
|                   | N            | Pourcentage | N        | Pourcentage | N     | Pourcentage |
| Sexe * Bloodgroup | 10           | 100,0%      | 0        | 0,0%        | 10    | 100,0%      |

Tableau croisé Sexe \* Bloodgroup

|       |                   |                   | Bloodgroup |        |        |        | Total |
|-------|-------------------|-------------------|------------|--------|--------|--------|-------|
|       |                   |                   | AB         | A      | B      | O      |       |
| Sexe  | Homme             | Effectif          | 2          | 1      | 1      | 1      | 5     |
|       |                   | % dans Bloodgroup | 66,7%      | 33,3%  | 50,0%  | 50,0%  | 50,0% |
|       | Femme             | Effectif          | 1          | 2      | 1      | 1      | 5     |
|       |                   | % dans Bloodgroup | 33,3%      | 66,7%  | 50,0%  | 50,0%  | 50,0% |
| Total | Effectif          | 3                 | 3          | 2      | 2      | 10     |       |
|       | % dans Bloodgroup | 100.0%            | 100.0%     | 100.0% | 100.0% | 100.0% |       |

## 3.2 Relations entre variables quantitatives

Les deux techniques statistiques les plus couramment utilisées pour analyser les relations entre les variables continues sont la corrélation de Pearson et la régression linéaire.

De nombreuses personnes utilisent le terme corrélation pour désigner l'idée d'une relation entre des variables dans un modèle. En d'autres termes, les variables sont corrélées entre elles parce que les changements d'une variable affectent l'autre.

Alors que la corrélation essaie simplement de déterminer si deux variables sont liées, la régression linéaire va encore plus loin et tente de prédire les valeurs d'une variable en fonction d'une autre variable.

### 3.2.1 Exécution de la procédure bivariée

Le coefficient de corrélation de Pearson est une mesure de la mesure dans laquelle il existe une relation linéaire (ligne droite) entre deux variables. Il a des valeurs comprises entre  $-1$  et  $+1$ , de sorte que plus la valeur absolue est grande, plus la corrélation est forte. Par exemple, une corrélation de  $+1$  indique que les données tombent sur une ligne droite parfaite inclinée vers le haut (relation positive), et une corrélation de  $-1$  représente les données formant une ligne droite parfaite inclinée vers le bas (relation négative). Une corrélation de  $0$  indique qu'il n'existe aucune relation linéaire.


Pour tester une corrélation, procédez comme suit :

- a) Choisissez **Analyse**  $\Rightarrow$  **Corrélation**  $\Rightarrow$  **Bivarié**.

La boîte de dialogue **Corrélations bivariées** s'affiche.

Dans cet exemple, vous étudierez si la glycémie est liée au poids. Notez qu'il n'y a pas de désignation de variables dépendantes et indépendantes. Les corrélations seront calculées sur toutes les paires de variables.

- b) Sélectionnez les variables **Weight** et **Bloodsugar** et placez-les dans la zone Variables, comme illustré à la Figure ci-dessous.



- c) Cliquez sur le bouton **Options** et cochez l'option « **Ecart des produits croisés et covariances** »
- d) Cliquez sur **Poursuivre**, puis sur **OK**.

e) La sortie résultante, illustrée dans les figures ci-dessous.

### → Corrélations

| Corrélations |                                      | Weight    | Bloodsugar |
|--------------|--------------------------------------|-----------|------------|
| Weight       | Corrélation de Pearson               | 1         | ,925**     |
|              | Sig. (bilatérale)                    |           | ,000       |
|              | Somme des carrés et produits croisés | 17694,596 | 475,289    |
|              | Covariance :                         | 1966,066  | 52,810     |
|              | N                                    | 10        | 10         |
| Bloodsugar   | Corrélation de Pearson               | ,925**    | 1          |
|              | Sig. (bilatérale)                    | ,000      |            |
|              | Somme des carrés et produits croisés | 475,289   | 14,927     |
|              | Covariance :                         | 52,810    | 1,659      |
|              | N                                    | 10        | 10         |

\*\* . La corrélation est significative au niveau 0.01 (bilatéral).

Dans cet exemple, vous avez une très forte corrélation positive (0,925) qui est statistiquement significative entre la glycémie et le poids.

D'une autre manière, du même tableau, nous pouvons calculer le coefficient de corrélation à partir de la matrice de covariance, comme suit :

$$r = \frac{\left(\frac{52.810}{10}\right)}{\sqrt{\left(\frac{1966.066}{10}\right)} * \sqrt{\left(\frac{1.659}{10}\right)}} = 0.925$$

### 3.2.2 Exécution de la procédure de régression linéaire simple

Les corrélations vous permettent de déterminer si deux variables continues sont linéairement liées l'une à l'autre. L'analyse de régression consiste à prédire le futur (l'inconnu) sur la base de données recueillies dans le passé (le connu). La régression vous permet de quantifier davantage les relations en développant une équation afin que vous puissiez prédire, par exemple, la glycémie en fonction de poids corporel du patient.

La régression linéaire est une technique statistique utilisée pour prédire une variable dépendante continue à partir d'une ou plusieurs variables indépendantes continues.

Puisque nous avons une forte corrélation linéaire entre la glycémie et le poids, nous pouvons effectuer une régression linéaire, comme suit :


a) **Sélectionnez Analyse ⇒ Régression ⇒ Linéaire.**

La boîte de dialogue Régression linéaire s'affiche.

Dans cet exemple, vous souhaitez prédire la glycémie à partir de poids. Vous pouvez placer la variable dépendante, la glycémie (**Bloodsugar**), dans la case Dépendant ; il s'agit de la variable pour laquelle vous souhaitez définir une équation de prédiction. Vous pouvez placer la variable prédictive **Weight** dans la zone Indépendant(s); c'est la variable que vous utiliserez pour prédire la variable dépendante.

b) Sélectionnez la variable **Bloodsugar** et placez-la dans la zone Dépendant.

- c) Sélectionnez la variable **Weight** et placez-la dans la zone indépendant(s), comme illustré dans la figure ci-dessous.



- d) Cliquez sur **OK** : SPSS effectue la régression linéaire.

## ➔ Régression

**Variables introduites/éliminées<sup>a</sup>**

| Modèle | Variables introduites | Variables éliminées | Méthode    |
|--------|-----------------------|---------------------|------------|
| 1      | Weight <sup>b</sup>   | .                   | Introduire |

a. Variable dépendante : Bloodsugar

b. Toutes les variables demandées ont été introduites.

**Récapitulatif des modèles**

| Modèle | R                 | R-deux | R-deux ajusté | Erreur standard de l'estimation |
|--------|-------------------|--------|---------------|---------------------------------|
| 1      | ,925 <sup>a</sup> | ,855   | ,837          | ,51969                          |

a. Prédicteurs : (Constante), Weight

**ANOVA<sup>a</sup>**

| Modèle |            | Somme des carrés | ddl | Carré moyen | F      | Sig.              |
|--------|------------|------------------|-----|-------------|--------|-------------------|
| 1      | Régression | 12,767           | 1   | 12,767      | 47,270 | ,000 <sup>b</sup> |
|        | Résidus    | 2,161            | 8   | ,270        |        |                   |
|        | Total      | 14,927           | 9   |             |        |                   |

a. Variable dépendante : Bloodsugar

b. Prédicteurs : (Constante), Weight

**Coefficients<sup>a</sup>**

| Modèle        | Coefficients non standardisés |                | Coefficients standardisés | t      | Sig. |
|---------------|-------------------------------|----------------|---------------------------|--------|------|
|               | B                             | Ecart standard | Bêta                      |        |      |
| 1 (Constante) | -,608                         | ,405           |                           | -1,502 | ,172 |
| Weight        | ,027                          | ,004           | ,925                      | 6,875  | ,000 |

a. Variable dépendante : Bloodsugar

La colonne B contient les coefficients de régression ( $a$  : la pente,  $b$  : l'ordonnée à l'origine) que vous utiliseriez dans une équation de prédiction. Dans cet exemple, la glycémie peut être prédite avec l'équation suivante :

$$\text{Bloodsugar} = a * \text{Weight} + b$$
$$\text{Bloodsugar} = 0.027 * \text{Weight} - 0.608$$

## 4. Représentation graphique des données

Le menu **Graphiques** dans SPSS comporte trois options principales : **Générateur de graphiques**, **Sélecteur de modèles de représentations graphiques** et **Boîtes de dialogue ancienne version**. Ces options sont différentes façons de faire le même travail. Les **Boîtes de dialogue ancienne version** sont les graphiques originaux de SPSS et sont principalement choisies par les personnes qui les utilisent depuis des années et qui trouvent trop difficile de passer à une autre option.

**Sélecteur de modèles de représentations graphiques** et **Générateur de graphiques** permettent de créer des graphiques de différentes manières. Dans « **Sélecteur de modèles de représentations graphiques** », vous sélectionnez d'abord les variables que vous souhaitez afficher. Sur la base de ces informations, différentes options de graphique sont proposées. **Générateur de graphiques** commence par présenter différents types de graphiques. Après avoir sélectionné un graphique, vous spécifiez les variables que vous utiliserez.

### 4.1 Construire des graphiques à la manière du Générateur de graphiques

SPSS contient **Générateur de graphiques**, qui utilise un affichage graphique pour vous guider à travers les étapes de construction de graphiques. Il vérifie ce que vous faites au fur et à mesure que vous avancez et ne vous permet pas d'utiliser des choses qui ne fonctionneront pas.

A travers un exemple, nous allons voir comment générer un graphe. Supposons que nous voulions tracer la **boîte à moustaches** de la variable « **Bloodsugar** ».

#### a) Choisissez Graphiques ⇒ Générateur de graphiques.

Un avertissement s'affiche, vous informant qu'avant d'utiliser cette boîte de dialogue, le niveau de mesure doit être défini correctement pour chaque variable de votre graphique. (Nous avons défini le niveau de mesure correct, vous pouvez donc continuer.)

#### b) Cliquez sur **OK** : la boîte de dialogue **Générateur de graphiques** s'affiche.


#### c) Assurez-vous que l'onglet **Galerie** est sélectionné : dans la liste "**Choisir parmi**", sélectionnez "**Boîtes à moustaches**" comme type de graphique.

#### d) Différents types de boîtes à moustaches apparaissent dans la galerie à droite de la liste, comme illustré dans la figure ci-dessous.



- e) Sélectionnez et faites glisser « **Boîte à Moustaches : 1D** » vers le panneau d'affichage.  
L'onglet **Propriétés des éléments** apparaît maintenant à droite du panneau d'aperçu en haut. Cet onglet vous permet de savoir quelles fonctionnalités de l'élément vous pouvez modifier. Par exemple, vous pouvez changer la statistique à afficher ou le style des graphes. Dans cet exemple, vous n'utilisez pas l'onglet **Propriétés des éléments**, alors fermez-le simplement.
- f) Dans la liste des variables, sélectionnez la variable **Bloodsugar** et faites-la glisser vers l'étiquette de l'axe Y dans le diagramme.  
L'affichage graphique à l'intérieur de la fenêtre d'aperçu du graphique ne représente jamais vos données réelles, même après avoir inséré des noms de variables.
- g) Cliquez sur le bouton **OK** pour produire le graphique : la sortie résultante, illustrée dans les figures ci-dessous.

➔ **GGraph**




## 4.2 Affichage d'une relation linéaire

Les étapes suivantes vous montrent comment construire un nuage de points simple :

- a) **Choisissez Graphiques ⇌ Générateur de graphiques.**
- b) Cliquez sur le bouton **OK** puis le bouton **Réinitialiser**.
- c) Dans la liste « **Choisir parmi** », sélectionnez **Dispersion/Points**.
- d) Sélectionnez le premier diagramme de nuage de points (Diagramme de dispersion: simple) et faites-le glisser vers le panneau en haut.
- e) Dans la liste Variables, sélectionnez **Weight** et faites-le glisser vers le rectangle intitulé X-Axis dans le diagramme.
- f) Dans la liste Variables, sélectionnez **Bloodsugar** et faites-le glisser vers le rectangle intitulé Y-Axis dans le diagramme.


g) Cliquez sur **OK** : le graphique dans la Figure ci-dessous s'affiche.

→ **GGraph**



- h) Double-cliquez sur le graphique produit : la boîte de dialogue « **Editeur de graphiques** » s'affiche.
- i) Appuyez sur l'icône « **Ajouter une courbe d'ajustement au total** », puis sur le bouton **Fermer**, et enfin fermez la fenêtre « **Editeur de graphiques** ».
- j) La sortie résultante, illustrée dans la figure ci-dessous.

**GGraph**



La droite superposée au nuage de points est la meilleure droite qui décrit la relation linéaire de l'équation:  $y = 0.03 * x - 0.61$ , où y représente **Bloodsugar** et x est le **Weight**.